

המכללה האקדמית להנדסה אפקה

[שם החוג / התוכנית]

מודל מרקוב חבוי גאוסיאני לזיהוי משטרים ולחיזוי כיוון יומי בשווקים פיננסיים

השוואה מבוקרת למודלי בסיס תחת פרוטוקול כרונולוגי מוגן-זליגה

עבודת גמר בקורס שיטות מתקדמות בלמידת מכונה

יש להשלים שם מלא	שם הסטודנט/ית:
יש להשלים מספר סטודנט	מספר סטודנט:
אם רלוונטי	שם הסטודנט/ית הנוסף/ת:
אם רלוונטי	מספר סטודנט נוסף:
יש להשלים	מרצה:

תאריך הגשה: יש להשלים

תקציר

עבודה זו בוחנת אם מודל מרקוב חבוי גאוסיאני (Gaussian Hidden Markov Model; HMM) הלומד משטרים סטטיסטיים סמויים משפר חיזוי של סימן התשואה ביום הבא ביחס למודלי בסיס פשוטים. הניסוי הקנוני כולל חמישה נכסים שנקבעו מראש — DIS , $BTC-USD$, TLT , GLD , SPY — ונתונים יומיים שהתבקשו לטווח 2014-01-01--2024-12-31. וקטור התכונות כולל תשואה לוגריתמית, תנודתיות נגררת ל-20 ימים, טווח תוך-יומי ושינוי לוגריתמי בנפח. החלוקה כרונולוגית וקבועה: כ-70% אימון, 15% אימות ו-15% מבחן מוחזק-בצד. זהו **פיצול מוחזק-בצד יחיד לכל נכס, ולא ניסוי rolling-origin**. שורות הגבול הוסרו כך שמטרת היום הבא בכל מקטע אינה חוצה למקטע הבא; ההתאמה של הסקייילר נעשתה על האימון בלבד. לכל נכס הותאמו מודלים עם $K \in \{2, 3, 4\}$ מצבים ושלושה זרעי אתחול קבועים. התצורה נבחרה לפי validation log-likelihood בלבד, ולא לפי ביצועי המבחן. כל 45 ההתאמות התכנסו. במבחן, דיוק הכיוון של ה-HMM הנבחר היה 58.50%, 53.40%, 50.24%, 50.45% ו-51.46%, בהתאמה לסדר הנכסים לעיל. ממוצע בלתי-משוקלל בין הנכסים היה 52.81%. מודל ממוצע האימון הפשוט השיג 52.99%: ארבע תוצאות היו שוויון ובי-BTC-USD ה-HMM היה נמוך ב-0.89 נקודת אחוז. לכן הממצא המרכזי הוא שלילי וזהיר: **בניסוי הקנוני ה-HMM לא גבר על מודל ממוצע האימון במדד DPA**. לצד זאת, המצבים שנלמדו הציגו הבדלים ניכרים בתנודתיות ובהתמדה, ולכן יש למודל ערך תיאורי אפשרי כייצוג של משטרים סטטיסטיים. אין בעבודה טענה לרווחיות מסחר, למובהקות סטטיסטית או לעליונות כללית של המודל.

מילות מפתח: Hidden Markov Model, משטרי שוק, סדרות זמן פיננסיות, חיזוי כיוון, זליגת מידע, DPA, בחירת מודל.

תוכן העניינים

1	מבוא ומוטיבציה
1	1.1 תרומות העבודה
2	שאלות המחקר והציפיות האמפיריות
3	רקע תאורטי: מודל מרקוב חבוי גאוסיאני
3.1	הגדרת המודל
3.2	מספר פרמטרים ומורכבות
3.3	פענוח ותחזית
4	נתונים, נכסים ובניית תכונות
4.1	יקום הנכסים ומקור הנתונים
4.2	וקטור התכונות
4.3	נרמול
5	פרוטוקול ניסויי מוגן-זליגה
5.1	חלוקה כרונולוגית יחידה
5.2	התאמה מרובת אתחולים ובחירת מודל
5.3	ארטיפקט קנוני ומקור המספרים
6	מודלי הבסיס
6.1	ממוצע אימון
6.2	התמדה
6.3	ממוצע נע
6.4	בסיס כיוון מותנה

6	7 מדדי הערכה
6	7.1 דיוק כיוון — DPA
6	7.2 שגיאת תשואה: MAE ו-RMSE
6	7.3 שגיאת מחיר: MAPE
6	7.4 לייקלי-הוד, קריטריוני מידע וזמן
6	8 תוצאות
7	8.1 בחירת התצורה והתכנסות
7	8.2 השוואת DPA
8	8.3 שגיאות תשואה ומחיר
9	8.4 מבנה המצבים שנבחרו
9	8.5 איורים קנוניים
10	9 דיון
10	9.1 הממצא המרכזי: ייצוג משטרים ללא יתרון כיווני
13	9.2 מדוע ממוצע האימון הוא בסיס קשה
13	9.3 בחירת K ולייקלי-הוד
13	9.4 פרשנות המצבים
13	9.5 משמעות חוצת-נכסים
13	9.6 אין מסקנה על רווחיות או מובהקות
14	10 מגבלות ואיומים על התוקף
14	11 מסקנות
15	12 שחזור ותיעוד
15	12.1 קבצים קנוניים
15	12.2 הרצת הניסוי
15	12.3 בניית המסמך
15	12.4 בדיקות עקיבות מומלצות

1 מבוא ומוטיבציה

סדרות זמן פיננסיות אינן מתנהגות בהכרח כתהליך יחיד ויציב. תקופות שקטות יחסית מתחלפות בתקופות תנודתיות, מבנה התלות עשוי להשתנות, ותצפיות קיצוניות נוטות להופיע באשכולות. רעיון "משטר השוק" מנסח אפשרות שלפיה ההתפלגות היוצרת את התצפיות משתנה לאורך הזמן בהתאם למצב שאינו נצפה ישירות. מודל מרקוב חבוי נותן לרעיון זה ייצוג הסתברותי מפורש: שרשרת מרקוב בדידה מתארת את המעברים בין המצבים הסמויים, והתפלגות פליטה מתארת את התצפיות בתנאי המצב [9, 11]. שימוש במשטרים סמויים בניתוח כלכלי ופיננסי מוכר גם ממודלי החלפת משטרים [6].

המוטיבציה אינה להניח מראש שקיימים "שוק שורי" ו"שוק דובי", אלא לבדוק אם חלוקה סטטיסטית שנלמדת מן הנתונים: (א) יוצרת מצבים בעלי מאפיינים נבדלים; ו-(ב) מסייעת לחיזוי כיוון התשואה ביום הבא ביחס לכללים פשוטים. ההבחנה חשובה: מודל יכול לתאר היטב אשכולות תנודתיות בלי לשפר תחזית נקודתית, ולהפך. כמו כן, הצלחה במדד כיוון אינה שקולה לרווח לאחר עלויות עסקה, מגבלות ביצוע וסיכון.

העבודה נשענת רעיונית על הצעת הפרויקט ועל מאמרם של Catello et al. [5], אך אינה משחזרת את המימוש שלהם. המאמר משתמש בייצוג ובפרוטוקול משלו, ואילו כאן נבחן Gaussian HMM רב-ממדי, מספר מצבים $K = 2, 3, 4$, חמישה נכסים ומודלי בסיס אחדים. שינוי מרכזי ביחס לחלק מהניסויים ההיסטוריים במאגר הוא פרוטוקול קנוני המתקן זליגת מטרות בגבולות ומונע בחירה ישירה על המבחן.

1.1 תרומות העבודה

1. ניסוח השוואה מבוקרת בין Gaussian HMM לבין ארבעה מודלי בסיס תחת אותו אופק חיזוי ואותו מבחן כרונולוגי.
2. שימוש בחלוקת Train/Validation/Test מוגנת-מטרה, ובהתאמת StandardScaler על האימון בלבד.
3. בדיקת $K \in \{2, 3, 4\}$ ושלושה אתחולים לכל K , תוך תיעוד התכנסות, מספר איטרציות, AIC, BIC וזמני ריצה.
4. הפרדה מפורשת בין מדדי חיזוי לבין פרשנות פנימית של מצבים, מטריצות מעבר והתמדה.
5. דיווח מלא של תוצאה שלילית: אין יתרון DPA ל-HMM על פני ממוצע האימון בניסוי הקנוני.

2 שאלות המחקר והציפיות האמפיריות

שאלת המחקר הראשית, בהתאם להצעה המקורית, היא:

האם HMM הלומד מצבי שוק סמויים משפר את חיזוי כיוון השינוי היומי ביחס למודלים פשוטים, וכיצד מספר המצבים החבויים משפיע על התוצאה?

מן השאלה הראשית נגזרות ארבע שאלות אופרטיביות:

1. **ביצועי חיזוי:** האם ה-DPA של המודל שנבחר באימות גבוה מזה של מודל ממוצע האימון, התמדה, ממוצע נע ושרשרת מרקוב נצפית?
2. **מורכבות ובחירה:** איזה שילוב של K וזרע משיג את validation log-likelihood הגבוה ביותר, והאם ההתאמות מתכנסות?

3. **מבנה סמוי:** האם המצבים שונים בתשואה הממוצעת, בתנודתיות, בשכיחות ובמשך הרצף הממוצע?

4. **הכללה בין נכסים:** האם דפוס הביצועים עקבי בנכס מנייתי רחב, זהב, אג"ח ארוך, קריפטו ומניה בודדת?

הציפייה התאורטית אינה מנוסחת כהשערת עליונות קשיחה. ל-HMM יתרון ייצוגי אפשרי כאשר יש מצבים מתמידים בעלי התפלגויות מובחנות; אך תשואות יומיות רועשות מאוד, ובסיס פשוט החוזה תמיד את סימן ממוצע האימון עשוי להיות קשה לניצוח כאשר שיעור הימים החיוביים גבוה מ-50%. לפיכך התוצאה השלילית היא תוצאה מדעית לגיטימית ולא כשל של הדיווח.

3 רקע תאורטי: מודל מרקוב חבוי גאוסיאני

3.1 הגדרת המודל

נסמן ב- $S_t \in \{1, \dots, K\}$ את המצב הסמוי ביום t , וב- $\mathbf{x}_t \in \mathbb{R}^d$ את וקטור התכונות הנצפה. הנחת מרקוב מסדר ראשון היא

$$P(S_t = j \mid S_{t-1} = i, S_{t-2}, \dots, S_1) = P(S_t = j \mid S_{t-1} = i) = a_{ij}, \quad (1)$$

כאשר $A = (a_{ij})$ היא מטריצת המעבר וכל שורה בה מסתכמת ל-1. וקטור ההתחלה הוא π , עם $\pi_i = P(S_1 = i)$.

ב-Gaussian HMM רב-ממדי, התפלגות הפליטה היא

$$\mathbf{x}_t \mid S_t = k \sim \mathcal{N}(\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \quad (2)$$

בניסוי זה $d = 4$ וסוג הקווריאנציה הוא full; לכן כל מצב מקבל מטריצת קווריאנציה מלאה משלו. הלייקלי-הוד של רצף התצפיות מתקבל מסכימה על כל רצפי המצבים האפשריים:

$$P(\mathbf{x}_{1:T} \mid \theta) = \sum_{s_{1:T}} \pi_{s_1} \left[\prod_{t=2}^T a_{s_{t-1}, s_t} \right] \left[\prod_{t=1}^T p(\mathbf{x}_t \mid S_t = s_t) \right]. \quad (3)$$

חישוב יעיל נעשה באמצעות אלגוריתם Forward; הפרמטרים נאמדים באלגוריתם Baum--Welch, מקרה של Expectation--Maximization [3, 11].

3.2 מספר פרמטרים ומורכבות

עבור K מצבים, d תכונות וקווריאנציה מלאה, מספר הפרמטרים החופשיים ששימש בארטיפקטים הוא

$$p = (K - 1) + K(K - 1) + Kd + K \frac{d(d + 1)}{2}. \quad (4)$$

כאשר $d = 4$, מתקבלים בהתאמה $p = 31, 50, 71$ עבור $K = 2, 3, 4$. קריטריוני המידע חושבו על האימון:

$$\text{AIC} = 2p - 2\ell_{\text{train}}, \quad (5)$$

$$\text{BIC} = p \log(n_{\text{train}}) - 2\ell_{\text{train}}. \quad (6)$$

ערך נמוך יותר עדיף בהינתן אותו סט נתונים, אך בפרוטוקול הקנוני הם נשמרו כאבחונים בלבד; הבחירה בפועל נעשתה לפי לייקלי-הוד באימות. העיקרון של איזון התאמה ומורכבות מוכר מ-[1, 12]; בחירת

מספר מצבים ב-HMM אינה רק שאלה של ערך קריטריון יחיד, אלא גם של יציבות ופרשנות [10].

3.3 פענוח ותחזית

מצבי המבחן פוענחו באופן "עבר בלבד": עבור כל יום מבחן t נבנה רצף המורכב לכל היותר מ-100 תצפיות האימון האחרונות ומכל תצפיות המבחן עד t ; המודל מפענח את הרצף והמצב האחרון נלקח כ- $\hat{S}_t$. לכן תצפיות מבחן מ- $t+1$ ואילך אינן משמשות לפענוח יום t . חשוב לדייק: זהו Viterbi-prefix decoding, לא הסתברות מסוננת מלאה ולא החלקה דו-כיוונית.

לכל מצב חושב ממוצע תשואות האימון $\bar{r}_k$. תחזית התשואה ליום הבא היא

$$\hat{r}_{t+1} = \sum_{j=1}^K a_{\hat{S}_t, j} \bar{r}_j. \quad (7)$$

כלומר, התחזית משלבת בין הערכת המצב הנוכחי, הסתברויות המעבר וממוצעי התשואה של המצבים. התווית החזויה היא חיובית אם $\hat{r}_{t+1} \geq 0$ ושילית אחרת. אותו סף, ≥ 0 , משמש לכל המודלים.

4 נתונים, נכסים ובניית תכונות

4.1 יקום הנכסים ומקור הנתונים

היקום הוגדר מראש ואינו תוצאה של חיפוש נכסים שבהם המודל הצליח:

- SPY — קרן סל רחבה על שוק המניות האמריקאי;
- GLD — חשיפה לזהב;
- TLT — אג"ח ממשלת ארה"ב לטווח ארוך;
- BTC-USD — נכס קריפטוגרפי הנסחר גם בסופי שבוע;
- DIS — מניה בודדת, הנשמרת גם כמקרה מחקר היסטורי אך אינה "מנצחת" שנבחרה לפי המבחן.

הנתונים נטענו באמצעות yfinance [2] כנתוני OHLCV יומיים, עם תאריך התחלה מבוקש 2014-01-01 ותאריך סיום מבוקש 2024-12-31. לחישוב תשואה ומחיר יעד נעשה שימוש ב-Adjusted Close כאשר הוא זמין; הטווח התוך-יומי משתמש ב-High, Low ו-Close. רשומות חסרות או אינסופיות הוסרו. מאחר שלוחות המסחר שונים, אין להסיק שמספר התצפיות זהה בין BTC-USD לבין הנכסים הסחירים בבורסה.

ה-manifest הקנוני שומר את טווח הבקשה ואת שיעורי החלוקה, אך אינו שומר את מספר התצפיות ואת תאריכי הגבול בפועל לכל נכס. מסיבה זו איננו ממציאים כאן תאריכים מדויקים שאינם קיימים בארטיפקט. חוסר זה מופיע במפורש במגבלות ובהמלצות לשחזור עתידי.

4.2 וקטור התכונות

עבור מחיר מתואם P_t , נפח V_t , גבוה H_t , נמוך L_t וסגירה C_t , נבנו ארבע תכונות:

$$r_t = \log(P_t/P_{t-1}), \quad (8)$$

$$\sigma_t^{(20)} = \text{sd}(r_{t-19}, \dots, r_t), \quad (9)$$

$$q_t = (H_t - L_t)/C_t, \quad (10)$$

$$v_t = \log(V_t/V_{t-1}). \quad (11)$$

מכאן $\mathbf{x}_t = (r_t, \sigma_t^{(20)}, q_t, v_t)$. המטרה היא $y_t = r_{t+1}$, ותאריך המטרה נשמר בנפרד כדי לאפשר בדיקת גבולות. התכונות משתמשות במידע עד סוף יום t בלבד. לכן תזמון התחזית המוצהר הוא **לאחר סגירת יום t** , כאשר הגבוה, הנמוך והנפח של אותו יום כבר ידועים, לצורך תחזית יום $t + 1$.

בחירת התכונות מנסה לתאר ארבעה היבטים: כיוון ועוצמת התנועה האחרונה; תנודתיות מקומית; טווח תוך-יומי; ושינוי בפעילות המסחר. היא אינה כוללת אינדיקטורים מקרו-כלכליים, חדשות, ספר פקודות או נתונים עתידיים. חלון התנודתיות גורם להסרת תצפיות הפתיחה שאין להן 20 ימי היסטוריה מלאה.

4.3 נרמול

לכל נכס הותאם StandardScaler על מטריצת האימון בלבד:

$$z_{t,j} = \frac{x_{t,j} - \hat{\mu}_{j,\text{train}}}{\hat{\sigma}_{j,\text{train}}}. \quad (12)$$

אותם פרמטרים שימשו להתמרת האימות והמבחן. שלב זה חיוני משום שהפליטה הגאוסיאנית רגישה לקני מידה, והתאמת הסקילר על כל התקופה הייתה מכניסה מידע מן העתיד.

5 פרוטוקול ניסויי מוגן-זליגה

5.1 חלוקה כרונולוגית יחידה

לאחר בניית התכונות, כל סדרה חולקה לפי סדר הזמן לכ-70% אימון, 15% אימות ו-15% מבחן. לא בוצע ערבוב. השורה האחרונה של מקטע האימון והשורה האחרונה של מקטע האימות הוסרו לפני השימוש, מפני שהמטרה שלהן — התשואה ביום הבא — שייכת כבר למקטע הבא. הקוד בודק ייחודיות ומונטוניות של האינדקס, אי-חפיפה, סדר כרונולוגי והימצאות תאריך היעד בתוך גבולות המקטע.

יש להדגיש שוב: למרות שמסמך הביקורת המליץ בעתיד על rolling-origin, הריצה הקנונית הזמינה היא **מבחן מוחזק-בצד יחיד לכל נכס**. אין בעבודה הצגה שגויה של חמישה נכסים כחמישה קפלים בזמן; כל נכס הוא סדרה אחרת וכל אחד מכיל fold=0 יחיד. לפיכך אין כאן ראייה ליציבות על פני חלונות זמן מרובים.

5.2 התאמה מרובת אתחולים ובחירת מודל

לכל נכס הותאמו באמצעות hmmlearn [7] תשעה מודלים: שלושה ערכי K ושלושה זרעים, 42, 123, 456. בכל התאמה נעשה שימוש ב-full covariance, לכל היותר 300 איטרציות וסף עצירה 10^{-4} . מבין ההתאמות שהתכנסו נבחר השילוב בעל validation log-likelihood הגבוה ביותר. מדדי המבחן לא השתתפו בפונקציית הבחירה.

לאחר הבחירה המודל הנבחר הותאם מחדש על האימון באותו זרע והוערך פעם אחת במבחן. האימות לא צורף לאימון מחדש. זהו כלל שחזור ברור, אף שהוא מוותר על נתונים זמינים; הוא נדון כמגבלה. בנוסף, קוד האבחון מחשב ושומר test log-likelihood לכל התחלה עוד לפני הבחירה. הבחירה

עצמה משתמשת רק באימות, אך בפרוטוקול עתידי עדיף למנוע אפילו חשיפה תפעולית מוקדמת למדדי מבחן.

5.3 ארטיפקט קנוני ומקור המספרים

כל המספרים בפרקי התוצאות נלקחו מן התיקיה

`experiments_canonical/canonical_20260810_014841`

ובפרט מן הקבצים `model_diagnostics.json`, `results.csv`, `manifest.json`, טבלאות המצבים ומטריצות המעבר לכל נכס. הריצה מזוהה כפרוטוקול גרסה 1.0; מזהה הריצה הוא `canonical_20260810_014841`, וה-`manifest` מציין את קיצור ה-`Git commit` `3a1cfa163599`. הארטיפקט הוא המקור הסמכותי לעבודה זו; תוצאות ישנות מתיקיות ניסוי אחרות אינן משולבות.

6 מודלי הבסיס

השוואה למודל מורכב היא משמעותית רק כאשר הבסיסים פשוטים, שקופים ומתוזמנים לאותו יעד.

6.1 ממוצע אימון

מודל `Naive -- train mean` חוזה לכל יום את ממוצע תשואת היום הבא באימון:

$$\hat{r}_{t+1} = \frac{1}{n_{\text{train}}} \sum_{i \in \text{train}} r_{i+1}. \quad (13)$$

זהו בסיס חשוב במיוחד ל-DPA: אם ממוצע האימון חיובי, כל התחזיות מסווגות כחיוביות, ולכן הדיוק שווה למעשה לשיעור הימים הלא-שליליים במבחן. הוא בוחן אם המבנה המורכב של ה-HMM מספק מידע כיווני מעבר לנטייה השולית.

6.2 התמדה

מודל `Naive -- persistence` קובע $\hat{r}_{t+1} = r_t$. הוא מייצג השערה קצרה ופשוטה שהשינוי האחרון ממשיך ליום הבא. בשוק שבו סימני תשואה כמעט בלתי-תלויים, ביצועיו צפויים להיות קרובים לאקראי.

6.3 ממוצע נע

מודל `Moving Average 5` חוזה את ממוצע חמש התשואות האחרונות. הוא מפחית רעש אך עלול לפגור אחרי שינוי. בחישוב המבחן הקנוני נבנה הרצף מן האימון ומהמבחן; ערכי מבחן קודמים זמינים בזמן החיזוי, אך נתוני אימות לא צורפו למסלול החישוב. זהו פרט מימוש שיש לשמר בשחזור ולשפר בפרוטוקול הבא.

6.4 בסיס כיוון מותנה

המודל המכונה בארטיפקט `Discrete Markov Chain` ממפה את כיוון התשואה הנוכחית $d_t = \mathbb{I}[r_t \geq 0]$ לתשואה הצפויה ביום הבא, הנאמדת באימון:

$$\hat{r}_{t+1} = \mathbb{E}_{\text{train}}[r_{t+1} \mid d_t]. \quad (14)$$

לכן זהו למעשה **מנבא ממוצע מותנה בכיוון** ולא מימוש מלא הנשמר כמטריצת הסתברויות מעבר בין תוויות. השם נשמר לצורך התאמה ל-`results.csv`, אך הפרשנות המדעית משתמשת בהגדרה המדויקת.

7 מדדי הערכה

7.1 דיוק כיוון – DPA

נגדיר $d(r) = \mathbb{I}[r \geq 0]$ אז

$$DPA = \frac{1}{N} \sum_{t=1}^N \mathbb{I}[d(\hat{r}_{t+1}) = d(r_{t+1})]. \quad (15)$$

ערך גבוה יותר פירושו ששיעור גדול יותר של סימני התשובה נחזה נכון. המדד עונה ישירות לשאלת המחקר, אך מתעלם מגודל הטעות, מחוסר איזון בין ימים חיוביים ושליילים ומעלויות מסחר. בפרט, 58% אינו תשובה של 58%.

7.2 שגיאת תשובה: MAE ו-RMSE

$$MAE = \frac{1}{N} \sum_{t=1}^N |r_{t+1} - \hat{r}_{t+1}|, \quad (16)$$

$$RMSE = \sqrt{\frac{1}{N} \sum_{t=1}^N (r_{t+1} - \hat{r}_{t+1})^2}. \quad (17)$$

MAE מודד טעות מוחלטת טיפוסית ביחידות של תשובה לוגריתמית. RMSE מעניש חזק יותר טעויות גדולות ולכן רגיש לימים קיצוניים. ערך נמוך יותר עדיף. אף אחד מהמדדים אינו מודד איכות של הסתברות מצב או רווחיות.

7.3 שגיאת מחיר: MAPE

מחיר החיזוי נגזר מן התשובה: $\hat{P}_{t+1} = P_t \exp(\hat{r}_{t+1})$. לאחר מכן

$$MAPE = \frac{100}{N} \sum_{t=1}^N \left| \frac{P_{t+1} - \hat{P}_{t+1}}{P_{t+1}} \right|. \quad (18)$$

המדד אינטואיטיבי באחוזים, אך מחיר יום המחר קרוב בדרך כלל למחיר היום, ולכן MAPE נמוך אינו מעיד לבדו על חיזוי כיוון טוב. באופן כללי ל-MAPE מגבלות ידועות, בפרט כאשר המכנה קרוב לאפס [8]; בעבודה זו מחירי הנכסים חיוביים, אך המגבלה הפרשנית נותרת.

7.4 לייקלי-הוד, קריטריוני מידע וזמן

Log-likelihood מודד את התאמת המודל ההסתברותי לרצף התכונות, לא את שגיאת התשובה החזויה. ערכים פחות שליליים טובים יותר כאשר משווים על אותו רצף. AIC/BIC מתקנים את לייקלי-הוד של האימון בגין מספר הפרמטרים. זמני הריצה שנשמרו קצרים מאוד אך אינם מדד חומרה אחיד לחלוטין: בבסיסים הם בעיקר זמן חיזוי/הערכה, וב-HMM בעיקר זמן התאמה. לכן הם מוצגים כאבחון הנדסי ולא כהשוואת יעילות פורמלית.

8 תוצאות

פרק זה מתאר מה נצפה בארטיפקט הקנוני. הסברים אפשריים ומשמעויות נשמרים לפרק הדיון.

8.1 בחירת התצורה והתכנסות

כל 45 ההתאמות — חמישה נכסים כפול שלושה ערכי K כפול שלושה זרעים — מסומנות כמתכנסות. טבלה 1 מציגה את הבחירה לפי האימות ואת אבחוני האימון של אותה התחלה. ארבעה נכסים בחרו $TLT; K = 4$; $K = 3$. אין להסיק מכך שארבעה מצבים הם אמת כלכלית, שכן פונקציית הבחירה היא לייקלי-הוד באימות ולא איכות פרשנית.

טבלה 1: התצורה שנבחרה לכל נכס לפי validation log-likelihood. AIC/BIC חושבו על האימון ונשמרו כאבחונים; הם לא היו כלל הבחירה.

נכס	K	זרע	לייקלי-הוד אימות	איטרציות	AIC	BIC
SPY	4	456	-1901.34	70	11754.02	12148.82
GLD	4	123	-1763.71	117	16102.88	16497.68
TLT	3	123	-2649.73	41	14224.70	14502.73
BTC-USD	4	123	-2001.57	94	20200.49	20617.16
DIS	4	123	-2063.10	55	13483.82	13878.62


8.2 השוואת DPA

טבלה 2 מציגה את DPA של כל המודלים. מודל ממוצע האימון וה-HMM השיגו בדיוק אותו DPA בארבעה נכסים. ב-BTC-USD, ה-HMM השיג 50.45% לעומת 51.34%, פער של -0.89 נקודות אחוז. אין נכס שבו ה-HMM גבר על ממוצע האימון.

טבלה 2: דיוק כיוון במבחן (DPA, באחוזים). מודל ה-HMM הוא התצורה שנעלה לפי האימות.

מודל	SPY	GLD	TLT	BTC-USD	DIS
ממוצע אימון	58.50	53.40	50.24	51.34	51.46
התמדה	53.16	50.49	48.06	47.24	49.03
ממוצע נע 5	53.16	51.70	51.21	45.99	50.24
ממוצע מותנה בכיוון	58.50	53.40	50.24	51.34	50.97
Gaussian HMM נבחר	58.50	53.40	50.24	50.45	51.46

הממוצע הבלתי-משוקלל של DPA על פני חמשת הנכסים הוא 52.81% ל-HMM ו-52.99% לממוצע האימון. אין לראות בממוצע זה אומדן אוכלוסייה: מדובר בחמישה נכסים הטרוגניים ובפיצול יחיד. ב-TLT, הממוצע הנע השיג את ה-DPA הגבוה ביותר, 51.21%; בשאר הנכסים מודל ממוצע האימון היה בשוויון על המקום הראשון או טוב יותר מן ה-HMM.



איור 1: השוואת DPA בין ה-HMM שננעל באימות לבין מודל הבסיס החזק ביותר לכל נכס. ה-HMM אינו מנצח באף נכס: שלושה שוויונות ושני הפסדים כאשר ההשוואה היא לבסיס החזק ביותר, כולל הממוצע הנע ב-TLT. זהו סיכום תיאורי של מבחן מוחזק-בצד יחיד.

8.3 שגיאות תשואה ומחיר

טבלה 3 מציגה את מדדי ה-HMM במבחן, וטבלה 4 משווה אותו ישירות לממוצע האימון. ההבדלים קטנים מאוד בארבעת הנכסים המסורתיים; ב-BTC-USD שתי שגיאות התשואה של ה-HMM גבוהות יותר.

טבלה 3: מדדי המבחן של ה-HMM הנבחר. MAE/RMSE ביחידות תשואה לוגריתמית; MAPE באחוזי מחיר.

נכס	DPA (%)	MAE	RMSE	MAPE (%)	זמן (שניות)
SPY	58.50	0.005754	0.007657	0.5756	0.305
GLD	53.40	0.006637	0.008751	0.6636	0.446
TLT	50.24	0.007937	0.009971	0.7944	0.504
BTC-USD	50.45	0.017997	0.025609	1.7946	1.325
DIS	51.46	0.010840	0.016303	1.0848	0.955

טבלה 4: השוואת שגיאות תשואה: HMM לעומת ממוצע האימון. ערך נמוך יותר עדיף.

נכס	MAE HMM	MAE mean	RMSE HMM	RMSE mean
SPY	0.005754	0.005763	0.007657	0.007656
GLD	0.006637	0.006635	0.008751	0.008755
TLT	0.007937	0.007941	0.009971	0.009971
BTC-USD	0.017997	0.017849	0.025609	0.025396
DIS	0.010840	0.010832	0.016303	0.016304

8.4 מבנה המצבים שנבחרו

טבלה 5 מסכמת דוגמאות בולטות מטבלאות מצב האימון. מספרי המצבים הם תוויות שרירותיות; אין להשוות ``מצב 0'' בין נכסים. השמות בעמודה האחרונה הם תיאור סטטיסטי בלבד.


טבלה 5: מאפיינים נבחרים של מצבים על נתוני האימון. תשואה ותנודתיות באחוזים ליום; השכיחות באחוזים; משך ממוצע בימים רצופים.

נכס/מצב	שכיחות	תשואה ממוצעת	תנודתיות יומית	תנודתיות נגזרת	משך	תיאור סטטיסטי
SPY/0	38.16	0.061	0.664	0.693	26.18	תנודתיות נמוכה-בינונית, מתמיד
SPY/2	29.46	0.091	0.416	0.424	33.29	התנודתיות הנמוכה ביותר
SPY/3	4.06	-0.442	3.710	2.929	8.67	נדיר, שלילי ותנודתי מאוד
GLD/0	13.38	-0.102	1.410	0.905	1.16	שלילי וקצר-משך
TLT/0	64.29	0.015	0.616	0.624	72.65	דומיננטי ומתמיד
TLT/1	2.45	0.179	2.816	2.300	4.27	נדיר ותנודתי
BTC-USD/1	11.40	-6.038	4.676	4.930	1.43	שלילי קיצוני וקצר
DIS/3	9.89	0.016	4.029	3.103	5.43	תנודתיות גבוהה

הערך החריג של 1/BTC-USD מדווח בדיוק כפי שהוא מופיע בארטיפקט, אך אין לפרשו מיד כ־משטר קריסה". הוא עשוי לשקף שילוב של תצפיות קיצוניות, מאפייני נפח או רגישות התאמת גאוסיאן; נדרש אימות נתונים ויציבות בין אתחולים לפני תווית כלכלית.


8.5 איורים קנוניים

איור 2 מציג את ציר הזמן של SPY בצבעי המצבים. הציר האופקי הוא תאריך והאנכי הוא מחיר; הצבע הוא מזהה מצב. התרשים נועד להראות אשכולות והתמדה, לא להוכיח שהמצבים היו ידועים בזמן אמת לאורך כל האימון. הוא כולל את האימון והמבחן כפי שהופקו בקוד הקנוני, אך אינו מציג את מקטע האימות.



איור 2: מחיר SPY צבוע לפי מצב ה-HMM הנבחר ($K = 4$). שינויי הצבע מתארים שיוך סטטיסטי; מספר המצב אינו בעל משמעות כלכלית כשלעצמו. מקור: הארטיפקט הקנוני.

איור 3 מציג את הסתברויות המעבר של SPY. הציר האנכי הוא מצב המקור והאופקי מצב היעד. הממוצע של איברי האלכסון הוא 0.9416, נתון התואם תקופות שהייה ממושכות יחסית. אולם ממוצע אלכסון גבוה לבדו אינו מבטיח חיזוי תשואה טוב.



איור 3: מטריצת המעבר של SPY, $K = 4$. ריכוז גבוה באלכסון מעיד על התמדה של שיוך המצב. מקור: הארטיפקט הקנוני.

איור 4 מרכז את מאפייני המצבים של SPY. יש להבחין בין ממוצע תנודתיות נגררת לבין סטיית התקן בפועל של התשואה בכל מצב; אלו כמויות שונות. מצב 3 נדיר, שלילי בממוצע ותנודתי במיוחד באימון. ב-TLT נבחרו שלושה מצבים. איור 5 מציג מבנה מתמיד, עם ממוצע אלכסון 0.9123. בהתאם לטבלת המצבים, מצב 0 תופס 64.29% מן האימון ונמשך בממוצע 72.65 ימים רצופים, ואילו מצב 1 נדיר וקצר יותר.

איור 6 מראה כי מצבי BTC-USD מפרידים בין אשכולות בעלי טווחי תשואה שונים. הציר האנכי הוא תשואה לוגריתמית יומית, והצבע הוא מצב. פיזור רחב וחרים רבים ממחישים מדוע RMSE ו-MAPE גבוהים יותר בנכס זה. עם זאת, הפרדה בדיעבד של תנודתיות אינה שקולה לדיוק גבוה בסימן היום הבא.


איור 7 מדגים גם ב-DIS שהבדל ברור בתנודתיות אינו מתרגם אוטומטית ליתרון כיווני. מצב 3 מציג תנודתיות יומית של 4.029%, אך ה-DPA הכולל של המודל נשאר זהה לממוצע האימון.

9 דיון


9.1 הממצא המרכזי: ייצוג משטרים ללא יתרון כיווני

הממצא החשוב ביותר הוא שה-HMM לא גבר על בסיס ממוצע האימון ב-DPA: 0 ניצחונות, 4 תוצאות שוויון והפסד אחד. זהו מבחן חזק יחסית לטענה שהמצבים מוסיפים מידע כיווני. בארבעת מקרי השוויון, ייתכן שהתחזיות של שני המודלים נבדלו בגודל אך לא בסימן, ולכן ה-DPA זהה. השוואות ה-MAE/RMSE מראות רק הבדלים זעירים ומעורבים, ללא דפוס של עליונות עקבית.


התוצאה אינה סותרת את קיומם של משטרים בתנודתיות. התכונות כוללות במפורש תנודתיות נגררת וטווח יומי, וה-HMM מסוגל להפריד היטב אשכולות של פיזור. אך תחזית סימן r_{t+1} דורשת קשר בין המצב הנוכחי לבין תוחלת התשואה העתידית. אם מצבים נבדלים בעיקר בשונות ולא בתוחלת, או אם תוחלות המצב קטנות ולא יציבות, שיפור בייצוג אינו מוביל בהכרח לשיפור ב-DPA.




איור 4: מאפייני מצבים עבור SPY על נתוני האימון. האיור תיאורי ואינו מדד לביצועי תחזית. מקור: הארטיפקט הקנוני.



איור 5: מטריצת המעבר של TLT, המודל היחיד שבו נבחר $K = 3$. מקור: הארטיפקט הקנוני.



איור 6: תשואות לוגריתמיות של BTC-USD בצבעי המצבים שנלמדו, $K = 4$. מקור: הארטיפקט הקנוני.



איור 7: מאפייני המצבים של DIS על האימון. מצב בעל תנודתיות גבוהה אינו בהכרח מצב בעל ערך תחזיתי לכיוון. מקור: הארטיפקט הקנוני.

9.2 מדוע ממוצע האימון הוא בסיס קשה

ב-SPY ממוצע האימון כנראה חיובי ולכן תחזית קבועה חיובית משיגה 58.50%, שיעור הימים הלא-שליליים במבחן. מודל מורכב חייב לא רק לזהות ימים שליליים, אלא לעשות זאת בדיוק מספיק בלי להפוך ימים חיוביים רבים לשליליים. תוצאה זו ממחישה מדוע יש לדווח על הבסיס ולא להשוות ל-50% באופן נאיבי. 58.50% ל-HMM אינו בהכרח עדות ליכולת תזמון, אם אותה תוצאה מתקבלת מתחזית קבועה.

ב-TLT, לעומת זאת, DPA של ממוצע האימון קרוב ל-50%, והממוצע הנע עדיף בכ-0.97 נקודת אחוז. זהו רמז אפשרי לכך שתלות קצרה מקומית עשויה להיות שימושית יותר מן החלוקה למשטרים עבור אותו חלון מבחן, אך פיצול יחיד אינו מספיק כדי לקבוע זאת.

9.3 בחירת K ולייקלי-הוד

בחירה לפי validation log-likelihood העדיפה $K = 4$ בארבעה נכסים. מודל מורכב יכול לשפר לייקלי-הוד משום שהוא מתאר טוב יותר התפלגויות הטרוגניות, במיוחד זנבות ואשכולות תנודתיות. אולם היעד של הבחירה והיעד של המחקר אינם זהים: לייקלי-הוד מתייחס לווקטור התכונות, בעוד DPA מתייחס לסימן התשואה הבאה. אי-התאמה זו יכולה להסביר מדוע בחירת $K = 4$ לא שיפרה חיזוי כיוון.

AIC/BIC שנשמרו אינם בסיס לבחירה הקנונית, ואין להשוות ערכיהם בין נכסים בעלי מספרי תצפיות והתפלגויות שונים. בתוך נכס ניתן להשתמש בהם כאבחון משלים, אך נכון יותר בפרוטוקול עתידי להגדיר מראש אם הבחירה מיועדת לצפיפות, לתחזית או לפשרה ביניהן. בחירה על DPA באימות הייתה מתאימה יותר לשאלת הכיוון, אך גם רגישה יותר לרעש ולסף; בחירה לפי BIC הייתה שמרנית יותר כלפי מורכבות.

9.4 פרשנות המצבים

ב-SPY, מצב 3 מתאפיין בשכיחות 4.06%, תשואה יומית ממוצעת -0.442% ותנודתיות 3.710%; זהו הבדל סטטיסטי ברור מן המצבים האחרים. ב-TLT, מצב 1 נדיר ותנודתי לעומת מצב 0 הדומיננטי. ב-DIS, מצב 3 תנודתי מאוד. תיאורים כגון "נדיר ותנודתי" נתמכים בטבלה; תוויות כגון "משבר", "שורי" או "דובי" דורשות בדיקה מול אירועים, יציבות בין זרעים ורווחי סמך, ולכן אינן מוקצות כאן.

גם תוויות המספר עצמן אינן מזהות בין התאמות: label switching מאפשר למצב זהה רעיונית לקבל מספר אחר בזרע אחר. הארטיפקט מתעד את כל האתחולים אך אינו כולל התאמת תוויות ומדדי ARI ביניהם. לכן אי אפשר לטעון עדיין ליציבות סמנטית של המצבים. עבודות על משטרים מדגישות את הצורך להפריד בין התאמה סטטיסטית לבין סיפור כלכלי [4].

9.5 משמעות חוצת-נכסים

היעדר יתרון אינו מובל לסוג נכס אחד: הוא מופיע במניות רחבות, זהב, אג"ח, קריפטו ומניה בודדת. מצד שני, המדגם של חמש סדרות קטן ונבחר לצורך גיוון, לא לצורך דגימה סטטיסטית של כל שוקי ההון. BTC-USD שונה בלוח המסחר, בתנודתיות ובאיכות אפשרית של נתוני נפח; אין לאחד את כל הנכסים ללא משקלול או מודל היררכי. הממוצע בין הנכסים הוא סיכום תיאורי בלבד.

9.6 אין מסקנה על רווחיות או מובהקות

הניסוי אינו אסטרטגיית מסחר. לא הוגדרו פוזיציות, עלויות, החלקת מחיר, מגבלות נזילות, תשואה מצטברת או סיכון. לכן אסור להסיק מן ה-DPA רווחיות. בנוסף, לא בוצע ניתוח תקף של תלות סדרתית, רווחי סמך או תיקון לריבוי השוואות. טענות מובהקות היסטוריות שנמצאו בטיטות ישנות אינן נתמכות בארטיפקט הקנוני ואינן מופיעות כאן.

10 מגבלות ואיומים על התוקף

1. **פיצול זמן יחיד:** התוצאה רגישה לתקופת המבחן המסוימת. אין rolling-origin, ולכן לא נבדקה יציבות על פני משטרי מאקרו שונים.
2. **יקום קטן:** חמישה נכסים אינם מאפשרים הכללה לכל השווקים. DIS היא גם מקרה היסטורי מסוים, אף שלא נבחרה לפי הצלחה בריצה הקנונית.
3. **חסרי manifest provenance:** תאריכי גבול בפועל, מספר תצפיות לכל מקטע, גרסאות החבילות והאשים של קובצי הקלט אינם נשמרים. השחזור תלוי במקור נתונים חיצוני שעלול להשתנות.
4. **אימות אינו מצורף מחדש:** לאחר הבחירה המודל מאומן שוב על האימון בלבד. הדבר מונע בלבול בפרוטוקול אך אינו מנצל את כל המידע שקדם למבחן.
5. **בחירה לפי צפיפות ולא לפי יעד החיזוי:** validation log-likelihood עשוי להעדיף הפרדת תנודתיות שאינה משפרת סימן תשואה.
6. **חשיפה תפעולית ללייקלי-הוד מבחן:** הקוד חישב test log-likelihood לכל התחלה לפני הבחירה, אף שהבחירה עצמה אינה משתמשת בו. פרוטוקול קשיח יותר ימנע חישוב כל מדד מבחן עד לנעילה.
7. **פענוח נקודתי ולא הסתברותי:** התחזית משתמשת במצב Viterbi יחיד; אי־ודאות פוסטרירית אינה משוקללת. סביב גבולות מצב הדבר עלול להיות לא יציב.
8. **הנחת גאוסיאן:** תשואות פיננסיות עשויות להיות כבדות־זנב וא־סימטריות. ריבוי מצבים עלול לשמש תחליף גם להתפלגות פליטה מתאימה יותר.
9. **בסיס "שרשרת מרקוב":** המימוש הוא ממוצע מותנה בכיוון ולא מטריצת מעבר מפורשת; יש לתקן את השם או את המימוש.
10. **רצף הקשר:** חישוב הממוצע הנע והערכת המודל אינם משתמשים במקטע האימות כהיסטוריה לאחר הבחירה. בנוסף, גרפי הריצה מחברים אימון ומבחן ומדלגים על האימות, ולכן הם איורי המחשה ולא ציר זמן מלא.
11. **זמן ריצה לא אחיד:** זמני הבסיס וה־HMM אינם כוללים בדיוק אותם שלבים, ולכן אין להסיק מהם יחס האצה מדויק.
12. **היעדר הסקה סטטיסטית:** ללא תחזיות יום־יום שמורות לכל מודל, block bootstrap או מבחן זוגי תלוי־זמן לא ניתן לכמת אי־ודאות בפערי DPA.

11 מסקנות

העבודה בדקה באופן קנוני וזהיר אם Gaussian HMM עם מצבים סמויים משפר חיזוי כיוון יומי. הפרוטוקול תיקן זליגת מטרה בגבולות, שמר על סדר כרונולוגי, התאים נרמול באימון בלבד, בדק $K = 2, 3, 4$ בשלושה אתחולים ובחר לפי אימות לפני הערכת מבחן. התוצאה המרכזית ברורה: ה־HMM **לא ניצח** את מודל ממוצע האימון ב־DPA. הממוצע בין הנכסים היה 52.81% לעומת 52.99%; נרשמו ארבעה שוויונות והפסד אחד. לפיכך אין בסיס לטעון לעליונות בחיזוי, למובהקות או לרווחיות. במקביל, המודל זיהה מצבים בעלי שכיחויות, תנודויות ומשכי שהייה שונים, ובכך סיפק ייצוג תיאורי מעניין של הטרוגניות בשוק.

הניסוי הבא המתבקש הוא rolling-origin שנקבע מראש, עם מספר חלונות מבחן לא-חופפים, התאמת תוויות בין זרעים, שמירת תחזיות ברמת היום ו־block bootstrap לפערים מול בסיסים. ראוי גם להשוות פליטות כבדות־זנב או מודל Hidden Semi-Markov, ולבחון בחירה לפי יעד חיזוי באימות. עד אז, המסקנה המדעית היא צנועה: זיהוי משטרים סטטיסטיים אינו מבטיח יתרון בחיזוי הכיוון של היום הבא.

12 שחזור ותיעוד

12.1 קבצים קנוניים

מבנה הקבצים הדרוש לקריאת הדוח הוא:

```
experiments_canonical/canonical_20260810_014841/
  manifest.json
  results.csv
  model_diagnostics.json
  SPY/ GLD/ TLT/ BTC-USD/ DIS/
reports/
  report.tex
  references.bib
  images/
```

12.2 הרצת הניסוי

מן השורש של המאגר, הסקריפט `run_canonical.py` מפעיל את הפרוטוקול. ריצה חדשה יוצרת תיקייה חדשה בעלת חותמת זמן ואינה אמורה להחליף את הארטיפקט שעליו מבוסס דוח זה. היא דורשת גישה למקור הנתונים ולחבילות `numpy`, `pandas`, `scikit-learn`, `hmmlearn`, `matplotlib`, `seaborn` ו־`yfinance`. מאחר שהנתונים נמשכים משירות חיצוני, שחזור ביט־ל־ביט מחייב בעתיד גם `snapshot` קלט והאשים.

12.3 בניית המסמך

יש להריץ מתוך `reports/`:

```
xelatex -interaction=nonstopmode -halt-on-error report.tex
bibtex report
xelatex -interaction=nonstopmode -halt-on-error report.tex
xelatex -interaction=nonstopmode -halt-on-error report.tex
```

המסמך משתמש ב־DejaVu Sans לעברית עם `Renderer=HarfBuzz`; כל חבילות המתמטיקה, הגרפיקה, הכיתוב והקישורים נטענות לפני `polyglossia/bidi`. לאחר הקומפילציה יש לבדוק את המסמך עמוד־עמוד, לחפש אזהרות `Missing character`, לוודא שאין הפניות לא פתורות ולבדוק חילוץ טקסט עברי.

12.4 בדיקות עקיבות מומלצות

- לוודא שב־`results.csv` יש 25 שורות: חמישה מודלים לכל אחד מחמישה נכסים.
- לוודא שב־`model_diagnostics.json` יש תשע התאמות לכל נכס ושכולן מסומנות כמתכנסות.

- לבדוק ששילובי K /זרע בטבלה 1 תואמים לשדה selected.
- להשוות כל מספר בטבלאות 2--4 ישירות לקובץ התוצאות, בלי להעתיק מטיוטות היסטוריות.
- לוודא שכל קובצי האיור קיימים יחסית ל-/reports; אין בדוח נתיבים התלויים בספריית עבודה אחרת.

מקורות

- [1] Hirotugu Akaike. A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6):716--723, 1974.
- [2] Ran Aroussi. yfinance: Download market data from yahoo! finance's api. Python software and documentation, 2024.
- [3] Leonard E. Baum, Ted Petrie, George Soules, and Norman Weiss. A maximization technique occurring in the statistical analysis of probabilistic functions of markov chains. *The Annals of Mathematical Statistics*, 41(1):164--171, 1970.
- [4] Jan Bulla and Ingo Bulla. Stylized facts of financial time series and hidden semi-markov models. *Computational Statistics & Data Analysis*, 51(4):2192--2209, 2006.
- [5] Luigi Catello, Ludovica Ruggiero, Lucia Schiavone, and Mario Valentino. Hidden markov models for stock market prediction. *arXiv preprint arXiv:2310.03775*, 2023.
- [6] James D. Hamilton. A new approach to the economic analysis of nonstationary time series and the business cycle. *Econometrica*, 57(2):357--384, 1989.
- [7] hmmlearn developers. hmmlearn: Hidden markov models in python. Software documentation, 2024.
- [8] Rob J. Hyndman and Anne B. Koehler. Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4):679--688, 2006.
- [9] Kevin P. Murphy. *Machine Learning: A Probabilistic Perspective*. MIT Press, Cambridge, MA, 2012.
- [10] Jennifer Pohle, Roland Langrock, Floris M. van Beest, and Niels M. Schmidt. Selecting the number of states in hidden markov models: Pragmatic solutions illustrated using animal movement. *Journal of Agricultural, Biological and Environmental Statistics*, 22:270--293, 2017.
- [11] Lawrence R. Rabiner. A tutorial on hidden markov models and selected applications in speech recognition. *Proceedings of the IEEE*, 77(2):257--286, 1989.
- [12] Gideon Schwarz. Estimating the dimension of a model. *The Annals of Statistics*, 6(2):461--464, 1978.