

המכללה האקדמית להנדסה אפקה

תואר שני במערכות תבוניות

Gaussian HMM

לזיהוי משטרי שוק ולחיזוי כיוון יומי

ניתוח רב־נכסי ויציבות משטרים

והשוואה למודלי בסיס ול-Supervised ML

עבודת גמר בקורס שיטות מתקדמות בלמידת מכונה

מתן אשל

מספר סטודנט: 203502802

אוגוסט 2026

תקציר

עבודה זו בוחנת את השימוש ב-Gaussian Hidden Markov Model (HMM) בשתי רמות: חיזוי כיוון התשואה ביום הבא, וזיהוי משטרי שוק סמויים בעלי משמעות סטטיסטית. הניסוי הסופי כולל תשעה נכסים מייצגים — SPY, QQQ, IWM, TLT, GLD, HYG, BTC-USD, JPM ו-NVDA — עבור חלון בקשה 2014-01-01-2024-12-31. לכל יום מחושבים ארבעה Features: תשואה לוגריתמית, תנודתיות מתגלגלת ל-20 ימים, טווח תוך-יומי ושינוי לוגריתמי בנפח. החלוקה כרונולוגית ומוגנת מזליגה: Train, Validation ו-Test. בשלב בחירת ה-HMM ה-preprocessing מותאם על Train בלבד; לאחר נעילת K וה-seed המודל וה-scaler מותאמים מחדש על כל המידע שלפני ה-Test (Train+Validation). מודלי ה-ML Supervised הקבועים מאומנים על Train בלבד. לכל נכס נבדקו $K \in \{2, 3, 4\}$ וחמישה seeds. בחירת K ו-seed נעשתה לפי log-Validation likelihood בלבד. בנוסף ל-hard state assignment נבדקה תחזית המבוססת על כל וקטור ה-posterior. המודל הושוה לארבעה Baselines פשוטים ולשלושה מודלי ML: Supervised Logistic Regression, Forest Random Regression, HistGradientBoosting. מבחינת חיזוי, לא נמצא יתרון עקבי ל-HMM. ממוצע ה-DPA בין תשעת הנכסים היה Discrete ל-53.90%, Regression, Logistic ל-54.14%, train-mean, Naive ל-54.54%, 52.49% soft-posterior, HMM ל-53.06%, Forest, Random ל-53.27%, Chain, Markov Moving ל-52.06% HistGradientBoosting ו-persistence Naive hard-state; HMM ל-52.06%. Average range drawdown, volatility, states בעלי תשואה, ברמת ייצוג מבנה השוק התקבלו ממצאים תיאוריים ברורים יותר. ב-SPY, מודל $K = 4$ יצר states בעלי תשואה, entropy posterior עלה סביב מעברי state; מבנה המצבים היה ומשך שהיה שונים מאוד; ה-entropy posterior עלה סביב מעברי state; מבנה המצבים היה יציב מאוד בין seeds ומדד VIX, שלא שימש באימון, הפריד בין חלק מהמשטרים. בנוסף נמצא כי הקורלציות בין SPY לנכסים אחרים משתנות כתלות במשטר.

המסקנה המרכזית היא כי בפרויקט זה ה-HMM שימושי יותר כ-**latent market-state estimator** מאשר כמודל forecasting point ליום הבא. אין בעבודה טענה לרווחיות מסחר, למובהקות סטטיסטית של ההבדלים התיאוריים או ליתרון כללי של HMM על פני מודלים אחרים.

מילות מפתח: Hidden Markov Model, משטרי שוק, posterior uncertainty, directional prediction, walk-forward, Supervised Learning, Reinforcement Learning.

תוכן העניינים

1	1 מבוא ושאלות המחקר
1	2 נתונים, Features ופרוטוקול ניסוי
1	2.1 פאנל הנכסים
2	2.2 Feature Vector
2	2.3 יעד החיזוי והחלוקה הכרונולוגית
3	2.4 שחזור ומעקב אחר provenance
3	3 מתודולוגיה
3	3.1 Hidden Markov Model
3	3.2 בחירת מספר המצבים
3	3.3 Hard state לעומת Soft posterior
4	3.4 Persistence ומשך משטר
4	4 ניסויים, Baselines ומדדי הערכה
4	4.1 Baselines פשוטים
5	4.2 Supervised ML Baselines
5	4.3 מדדים
5	4.4 ניסוי Robustness
6	5 תוצאות: מבנה המשטרים
6	5.1 בחירת מודל ויציבות
7	5.2 פירוש states ב־SPY
8	5.3 Posterior uncertainty סביב מעברים
8	5.4 External validation מול VIX
9	5.5 Cross-asset behavior
9	6 תוצאות: חיזוי יום־קדימה
10	6.1 תמונה כללית
10	6.2 תוצאות לפי נכס
11	6.3 שגיאת magnitude: דוגמת SPY
11	6.4 למה DPA לבדו עלול להטעות
11	6.5 Hard state לעומת Soft posterior
11	6.6 Walk-forward robustness על SPY
12	7 דיון
12	7.1 למה חיזוי יום־קדימה נשאר קשה?
12	7.2 מה ה־HMM כן מוסיף?
13	7.3 Expressiveness מול robustness
13	7.4 האם ניתן לקרוא ל־"Bull", "Bear" ו־"Crash"?
13	7.5 משך המשטר והנחת Markov
13	8 הרחבה עתידית: Regime-aware Reinforcement Learning
13	8.1 ניסוח כ־Markov Decision Process
14	8.2 למה לשלב HMM בתוך RL?
14	8.3 אלגוריתמים אפשריים
14	8.4 מה מראה הספרות?
15	8.5 כיצד היינו מבצעים את הניסוי בצורה הוגנת?
15	9 מגבלות
16	10 מסקנות
16	א' שחזור והרצה

1 מבוא ושאלות המחקר

סדרות זמן פיננסיות אינן מתנהגות בהכרח כהליך יחיד ויציב. תקופות שקטות מתחלפות בתקופות תנודתיות, התפלגות התשואות משתנה, והקשר בין נכסים יכול להתחזק או להיחלש. מודלים מסוג switching regime מתארים מצב זה באמצעות משתנה חבוי שמייצג את הסביבה הסטטיסטית שבה השוק נמצא [7]. מודל מרקוב חבוי נותן לכך מסגרת הסתברותית פשוטה: state סמוי מתפתח לפי שרשרת מרקוב, והתצפיות נוצרות מהתפלגות שתלויה ב-state [12, 14].

הפרויקט התחיל משאלה יחסית ישירה: האם Gaussian HMM הלומד מצבי שוק סמויים יכול לשפר חיזוי של כיוון התשואה ביום הבא, וכיצד מספר המצבים K משפיע על התוצאה. רעיון דומה מופיע בעבודות המיישמות HMM לנתוני מניות לצורך forecasting [5]. עם זאת, לאחר הריצה הראשונית התברר שהשאלה החיזויית לבדה צרה מדי: גם אם DPA אינו גבוה, ייתכן שהמודל עדיין מזהה מבנה סטטיסטי חשוב שאינו נגיש ל-classifier רגיל.

לכן בגרסה הסופית הוגדרו שלוש שאלות מחקר:

1. **Forecasting:** האם HMM משפר חיזוי direction next-day ביחס ל-Baselines פשוטים ולמודלי ML Supervised המקבלים את אותם Features?

2. **Representation:** האם ה-Hidden States נבדלים באופן עקבי ב-daily volatility, return, volume range, behavior, occupancy drawdown, ו-persistence?

3. **information: Regime** האם identity state וה-uncertainty posterior מספקים מידע נוסף על מעברי משטר, VIX ומבנה הקורלציה בין נכסים?

ההבחנה בין forecasting לבין representation היא מרכזית. מודל יכול להיות חלש בחיזוי נקודתי ועדיין להיות שימושי כאומד של מצב חבוי. לכן העבודה אינה מחפשת רק "מודל מנצח", אלא בודקת איזה סוג מידע כל משפחת מודלים מספקת ומה ניתן להסיק ממנו באופן זהיר.

2 נתונים, Features ופרוטוקול ניסוי

2.1 פאנל הנכסים

במקום להוסיף מספר גדול של מניות דומות, נבחר פאנל קטן יחסית אך מגוון מבחינה כלכלית. הנתונים נמשכו דרך yfinance [2] עבור חלון בקשה של 2014-01-01-2024-12-31. הנכסים הם:

- SPY — שוק המניות האמריקאי הרחב, ומשמש גם כנכס ייחוס לניתוח cross-asset.
- QQQ — מניות צמיחה וטכנולוגיה גדולות.
- IWM — מניות small-cap.
- TLT — אג"ח ממשלתיות אמריקאיות ארוכות.
- GLD — זהב.
- HYG — אג"ח חברות, high-yield, כנכס אשראי מסוכן יחסית.
- BTC-USD — נכס אלטרנטיבי בעל volatility גבוהה.
- JPM — מניה גדולה מסקטור הפיננסים.
- NVDA — מניית צמיחה/high-beta.

המטרה בבחירה זו אינה לבצע picking stock אלא לבדוק אם אותה מתודולוגיה מתנהגת באופן דומה על asset classes בעלי מאפייני סיכון שונים. חשוב לציין שהטווח לעיל הוא חלון הבקשה המשותף; בפועל זמניות הנתונים שונה מעט בין הנכסים. בפרט, סדרת BTC-USD מתחילה מאוחר יותר ולכן

מכילה יותר ימי מסחר קלנדריים אך היסטוריה קצרה יותר בתחילת המדגם. כל split מחושב מתוך התצפיות הזמינות בפועל לכל נכס.

ההורדה בוצעה עם `auto_adjust=False`. לחישובי התשואה והיעד נעשה שימוש ב-`Adj Close` כאשר העמודה זמינה, וב-`Close` כ-`fallback`. אין השלמה מלאכותית של ימים חסרים: שורות OHLCV חסרות או ערכים לא-סופיים מוסרים, ולאחר בניית Features מוסרות גם שורות שאין עבורן היסטוריית `rolling` מספקת או `target` של יום הבא. בניתוח `cross-asset` נעשה שימוש רק בתאריכים החופפים בפועל בין הסדרות.

Feature Vector 2.2

לכל יום t נבנה וקטור תצפיות בן ארבעה רכיבים:

$$\mathbf{x}_t = \left[r_t, \sigma_t^{(20)}, R_t, \Delta \log V_t \right], \quad (1)$$

כאשר

$$r_t = \log \left(\frac{P_t}{P_{t-1}} \right) \quad (2)$$

היא התשואה הלוגריתמית, $\sigma_t^{(20)}$ היא סטיית התקן המתגלגלת של תשואות 20 הימים האחרונים, R_t הוא `range daily` המבוסס על `High` ו-`Low`, ו- $\Delta \log V_t$ הוא שינוי לוגריתמי בנפח. הבחירה בתכונות פשוטות נעשתה במכוון: הן מייצגות כיוון, תנודתיות, טווח מסחר ופעילות, בלי להעמיס אינדיקטורים טכניים שקשה לבודד את תרומתם.

כל statistic מתגלגל מחושב מהעבר וההווה בלבד. אין שימוש בנתוני יום $t+1$ בבניית Features של יום t .

2.3 יעד החיזוי והחלוקה הכרונולוגית

יעד החיזוי הוא סימן התשואה ביום הבא:

$$y_t = \mathbb{I}[r_{t+1} \geq 0]. \quad (3)$$

החלוקה היא כרונולוגית בקירוב 70% Train, 15% Validation ו-15% Test. אין `shuffle` כדי למנוע `leakage` בגבולות, שורה אחרונה בכל `partition` מוסרת אם ה-`target` שלה שייך כבר ל-`partition` הבא.

חשוב להבחין בין **שלב בחירת המודל לבין ההתאמה הסופית לפני Test**. בזמן השוואת מועמדי HMM, ה-`scaler` מותאם על Train בלבד, המועמדים מאומנים על Train ונמדדים על Validation. רק לאחר ש- K וה-`seed` ננעלים, ה-HMM הנבחר וה-`scaler` מותאמים מחדש על כל היסטוריית-`pre`, זהו Test, כלומר Train+Validation, ואז Test נשאר מחוץ לאימון ולהתאמת ה-`preprocessing`. זהו `refit` סטנדרטי לאחר `selection model` ואינו חושף את המודל ל-Test.

בריצת ה-`ML Supervised` הוגדרו `hyperparameters` קבועים מראש ולכן לא בוצע `model selection` על Validation. שלושת ה-`classifiers`, ובפרט ה-`scaler` של `Logistic Regression`, הותאמו על Train בלבד ונבדקו על אותו Test כרונולוגי. נשמרו `assertions` מפורשים כי `target-safe` `split` מתקיים, אין `shuffle` ו-Test אינו משמש לבחירה או התאמה. לכן ההשוואה משתמשת באותו

Vector Feature ובאותו Test, אך היקף היסטוריית האימון אינו זהה לחלוטין בין ה-HMM הסופי לבין מודלי ה-Supervised; הנקודה הזו נלקחת בחשבון בפרשנות התוצאות.

2.4 שחזור ומעקב אחר provenance

כל ריצה נשמרת בתיקייה חדשה עם manifest המכיל תאריך, Git, commit, גרסאות, packages, רשימת נכסים, Features, hyperparameters seeds, וסטטוס השלמה. הריצה המרכזית של ה-HMM היא extended_20260811_121957, והריצה של מודלי ה-ML Supervised היא supervised_20260811_133344. תוצאות קודמות נשמרו לצורך audit אך אינן משמשות לטענות המספריות בדוח זה.

3 מתודולוגיה

3.1 Hidden Markov Model

נסמן ב- $S_t \in \{1, \dots, K\}$ את ה-Hidden State בזמן t . הנחת Markov מסדר ראשון היא:

$$P(S_t | S_1, \dots, S_{t-1}) = P(S_t | S_{t-1}). \quad (4)$$

מטריצת המעבר A מכילה את ההסתברויות

$$a_{ij} = P(S_t = j | S_{t-1} = i), \quad (5)$$

ולכן האלכסון שלה מתאר persistence: ערך גבוה של a_{ii} פירושו שהמודל מצפה להישאר באותו state.

ב-HMM Gaussian התצפית המולטיווריאטית תלויה ב-state דרך Gaussian emission:

$$\mathbf{X}_t | S_t = k \sim \mathcal{N}(\mu_k, \Sigma_k). \quad (6)$$

בפרויקט נעשה שימוש ב-hmmlearn [8] עם covariance מסוג full. פרמטרי המודל נלמדים באמצעות Baum-Welch / EM [3]. האלגוריתם מבצע לסירוגין חישוב posterior על רצף המצבים ועדכון של ההסתברויות המעבר ופרמטרי הפליטה, עד convergence.

3.2 בחירת מספר המצבים

לכל נכס נבדקו $K = 2, 3, 4$ וחמישה seeds: 42, 123, 456, 789, 2026. הבחירה של K ו-seed נעשתה לפי Validation log-likelihood בלבד. AIC ו-BIC נשמרו כאבחוני complexity נוספים [16, 1], אך Test לא שימש בשום שלב של model selection.

בחירת מספר states ב-HMM אינה בעיה טריוויאלית: מודל עשיר יותר יכול לשפר likelihood אך גם ליצור states נדירים או רגישים לאתחול [13]. לכן בנוסף לציון ההתאמה נבדקו occupancy ויציבות seeds. בין

3.3 Hard state לעומת Soft posterior

ב-decoding hard כל יום מקבל state יחיד. לצורך ההערכה מחוץ למדגם השתמשנו ב-past-only inference: עבור יום Test בזמן t , רצף הקלט נחתך כך שאינו כולל תצפיות אחרי t . לכן וקטור ההסתברויות שבו משתמשת התחזית הוא

$$\gamma_t(k) = P(S_t = k \mid X_{1:t}), \quad (7)$$

ולא posterior שמוחלק בעזרת כל רצף ה-Test העתידי. בפועל נשמר גם context מוגבל של היסטוריית Train/Validation כדי לאתחל את inference הרצפי, אך אין שימוש ב- $X_{t+1}, X_{t+2}, \dots$ בעת חיזוי יום $t + 1$.

בגרסת forecast, soft תחזית התשואה של היום הבא היא ממוצע משוקלל לפי γ_t , במקום להסתמך רק על $\arg\max$ המוטיבציה היא שיום שנמצא בדיוק בגבול בין שני regimes לא צריך להיחשב כאילו המודל בטוח לחלוטין ב-state אחד. אי-הוודאות מסוכמת באמצעות entropy מנורמלת:

$$H_t = - \frac{\sum_{k=1}^K \gamma_t(k) \log \gamma_t(k)}{\log K}. \quad (8)$$

H_t קרוב לאפס כאשר posterior מרוכז כמעט כולו ב-state אחד, וגדל כאשר כמה states מקבלים הסתברויות דומות.

3.4 Persistence ומשך משטר

ב-HMM מסדר ראשון משך השהייה ב-state הוא גאומטרי. הממוצע המשתמע מ-self-transition probability הוא:

$$E[D_i] = \frac{1}{1 - a_{ii}}. \quad (9)$$

בדוח משווים את הערך הזה ל-mean empirical decoded duration. השוואה זו אינה בודקת את כל התפלגות ה-duration, ולכן Hidden Semi-Markov Model נשאר הרחבה אפשרית כאשר רוצים למדל duration במפורש [4].

4 ניסויים, Baselines ומדדי הערכה

4.1 Baselines פשוטים

ה-HMM הושווה תחילה לארבעה כללים פשוטים, כדי לוודא שכל יתרון אינו נובע רק ממגמת שוק בסיסית:

- **Naive - train mean:** זהו השם שנשמר ב-artifact. בהערכת ה-Test הסופית התחזית הקבועה מבוססת למעשה על ממוצע `next_log_return` בכל היסטוריית ה-pre-Test הזמינה, כלומר, Train+Validation, לאחר סיום model selection.
- **Naive persistence:** מנבא שהכיוון הבא יהיה זהה לכיוון האחרון שנצפה.
- **Moving Average :5:** כלל סיבתי המבוסס על ממוצע נע קצר של תשואות זמינות עד היום הנוכחי.
- **Discrete Markov Chain:** מודל מעבר נצפה בין Up/Down ללא Hidden States; הפרמטרים נאמדים מהיסטוריית ה-pre-Test בלבד.

Supervised ML Baselines 4.2

- Logistic Regression עם $C = 1$ ו-scaling על Train בלבד.

- HistGradientBoostingClassifier עם 200 iterations, learning rate 0.05 ו-15 leaves לכל היותר.

4.3 מדדים

$$\text{DPA} = \frac{1}{N} \sum_{t=1}^N \mathbb{I}[\text{sign}(\hat{r}_{t+1}) = \text{sign}(r_{t+1})]. \quad (10)$$

עבור מודלי classification נמדדו גם Loss, ROC-AUC, Accuracy, Balanced Score. המדדים האחרונים חשובים משום ש-Accuracy רגיל עלול להיראות גבוה כאשר שיעור הימים החיוביים גבוה יחסית. עבור classifiers ה-DPA שקול ל-accuracy של מחלקת הכיוון; עבור המודלים שמחזירים $\hat{r}_{t+1}$, הכיוון נגזר מסימן התחזית.

4.4 ג'יסוי Robustness

1. **Seed stability:** התאמת כל K בחמישה seeds והשוואת חלוקת הימים באמצעות Adjusted Rand Index (ARI).

2. **Walk-forward על SPY:** שלושה windows, expanding כאשר בכל fold נבנים Train, Validation ו-Test חדשים באופן כרונולוגי.

3. **validation: cross-asset / External** השוואת states של SPY ל-VIX, שלא שימש באימון, ובחינת התנהגות נכסים אחרים כתלות ב-SPY state.

בדיקות אלה אינן נועדו לשפר את Test בדיעבד, אלא לבדוק אם המסקנות התיאוריות נשארות סבירות גם מעבר לריצה יחידה.

5 תוצאות: מבנה המשטרים

5.1 בחירת מודל ויציבות

בריצה המורחבת נבחר $K = 4$ עבור שמונה מתוך תשעת הנכסים; עבור TLT נבחר $K = 3$. הבחירה נעשתה לפי log-likelihood Validation בלבד. העובדה ש- $K = 4$ נבחר ברוב הנכסים אינה כשלעצמה הוכחה שזהו מספר states "אמיתי"; לכן נבדקה גם יציבות בין seeds.


ב-SPY, השוואת המועמדים מראה מדוע $K = 4$ נבחר. הטבלה משתמשת ב-seed בעל Validation log-likelihood הטוב ביותר לכל K , לפני ה-refit הסופי על Train+Validation:

Min occupancy (%)	BIC (Train)	Val. LL / obs.	Seed	K
30.19	14935.6	5.206-	789	2
4.16	13415.1	4.759-	123	3
4.06	12148.8	4.626-	456	4

טבלה 1: השוואת $K = 2, 3, 4$ עבור SPY בשלב בחירת המודל. log-likelihood Validation גבוה יותר (פחות שלילי) עדיף; BIC נמוך יותר עדיף.

גם likelihood Validation וגם BIC מעדיפים כאן את $K = 4$; AIC מציג אותו סדר העדפה. עם זאת, ה-occupancy המינימלי יורד לכ-4%. לכן לא הסתפקנו בקריטריון התאמה בלבד ובדקנו גם יציבות בין seeds ומשמעות סטטיסטית post-hoc של ה-states. לאחר בחירת $K = 4$ ו-456 seed, המודל הסופי הותאם מחדש על Train+Validation ב-SPY; ה-refit התכנס ב-125 iterations וזמן ההתאמה היה כ-0.79 שניות בסביבת הריצה המאומתת.

עבור SPY, ה-ARI הממוצע בין חמשת ה-seeds ב- $K = 4$ היה 0.995, עם מינימום של 0.992. גם NVDA ו-QQQ היו יציבים מאוד, עם ARI של כ-0.960 ו-0.984 בהתאמה. לעומת זאת, BTC-USD ו-GLD היו פחות יציבים ב- $K = 4$, עם ARI של כ-0.553 ו-0.681. לכן המסקנה אינה שכל נכס "בנוי מארבעה משטרים", אלא שהמודל העשיר יציב במיוחד בחלק מהנכסים ופחות באחרים.



איור 1: יציבות חלוקת ה-states בין seeds לפי ARI. ערכים קרובים ל-1 מצביעים על חלוקה דומה מאוד גם לאחר שינוי initialization.

5.2 פירוש states ב-SPY


SPY משמש מקרה המבחן המרכזי. הטבלה הבאה מסכמת את ארבעת ה-states על פני ההיסטוריה. השמות הם פרשנות post-hoc בלבד; הם לא הוזנו למודל.

משך ימים	Mean DD (%)	Range (%)	Vol. (%)	תשואה יומית (%)	שכיחות (%)	פרשנות	State
25.0	1.72-	0.841	0.692	0.053	34.31	Normal / moderate	0
32.4	0.42-	0.586	0.415	0.092	25.00	Calm / low-vol	1
8.0	15.28-	3.614	3.409	0.265-	4.46	Rare stress / crisis-like	2
35.2	8.11-	1.497	1.239	0.039	36.23	Persistent high-vol	3

טבלה 2: מאפייני states של SPY. Vol. היא סטיית תקן יומית ו-DD Mean הוא drawdown ממוצע.

State 2 בולט במיוחד: הוא נדיר, בעל תשואה יומית ממוצעת שלילית, volatility של כ-3.41%, range daily של כ-3.61%, drawdown mean של כ-15.3% ו-drawdown worst של כ-33.7%. לעומתו State 1 הוא state שקט עם volatility של כ-0.42% ו-drawdown קטן יחסית. זו הפרדה שמצדיקה לדבר על משטרים סטטיסטיים שונים, גם אם אין להם כלכליים חד-משמעיים.

התנהגות ה-volume מפרידה פחות בבירור בין המשטרים. ממוצע שינוי ה-log-volume היה בקירוב 0.21%, 0.00%, 2.11% ו-0.61% ב-States 0--3, בעוד ממוצע השינוי המוחלט נשאר בטווח צר יחסית של כ-23.9%--26.5%. לכן במקרה של SPY ההבדלים ב-volatility, range ו-drawdown משמעותיים יותר לפרשנות המשטרים מאשר ה-volume לבדו.




איור 2: מחיר SPY בתקופת ה-Test צבוע לפי ה-state הדומיננטי. הרצפים המתמשכים ממחישים שהמודל אינו מחליף state באופן אקראי בכל יום.

5.3 Posterior uncertainty סביב מעברים

ה-confidence posterior הממוצע ב-SPY הוא כ-96.6%. עם זאת, ה-entropy הממוצע בימי state switch הוא 0.307 לעומת 0.054 בלבד בימים ללא switch. גם בחלון של יום לפני/אחרי מעבר מתקבל entropy ממוצע של כ-0.236. לעומת זאת, המתאם בין entropy לבין return absolute הוא רק 0.027, והמתאם עם volatility rolling הוא כ-0.076.


הממצא מצביע על כך שה-posterior מכיל מידע על מידת הביטחון של המודל, ולא רק label. state. עם זאת, יש כאן נקודת זהירות חשובה: switch hard מוגדר לפי שינוי ב-argmax של אותו posterior, ולכן צפוי במידה מסוימת שימים סמוכים לגבול בין שני states יהיו גם ימים בעלי entropy גבוהה יותר. לכן הקשר בין entropy ל-switch משמש כאן בעיקר **diagnostic פנימי של ambiguity**, ולא validation חיצוני עצמאי של שינוי משטר. העובדה שה-entropy כמעט אינה מתואמת עם return או volatility rolling עדיין מראה שהיא אינה רק proxy פשוט לעוצמת התנודתיות.



איור 3: Posterior entropy לאורך תקופת ה-Test של SPY. קפיצות באנטרופיה מופיעות בעיקר סביב שינויי state.

5.4 External validation מול VIX

ה-VIX לא שימש Feature ולא השתתף באימון. לכן הוא משמש בדיקת post-hoc חיצונית של פרשנות ה-states, ולא בדיקת forecasting. בתקופת החפיפה של 412 ימי 1 State Test של SPY היה קשור ל-VIX ממוצע של 12.96, 0 State ל-15.34 ו-3 State ל-18.55. ב-3 State כ-26.1% מהימים היו מעל VIX=20, לעומת 6.15% ב-0 State ואפס ב-1 State.



איור 4: רמת VIX לפי state של SPY VIX אינו חלק מווקטור התכונות ולכן משמש אינדיקציה חיצונית לפרשנות המשטרים.

State 2 הנדיר לא הופיע בחפיפה זו ולכן אי אפשר להשתמש ב-VIX כדי לאמת אותו בתקופת ה-Test. בנוסף, entropy עצמו כמעט אינו מתואם עם רמת VIX, ולכן אין לזהות בין "איזודאות של ה-HMM" לבין "פחד בשוק".

Cross-asset behavior 5.5

כדי לבדוק האם state של SPY משקף מצב שוק רחב יותר, חושבו סטטיסטיקות של נכסים אחרים מותנות ב-SPY state. State 3 הקורלציה עם SPY מגיעה לכ-0.978 ב-QQQ, 0.773 ב-HYG, 0.631 ב-BTC-USD, 0.680 ב-JPM ו-0.769 ב-NVDA. באותו TLT state, נמצא בקורלציה קרובה לאפס ואף מעט שלילית (-0.044).

Asset	Corr. State 0	Corr. State 1	Corr. State 3
QQQ	0.924	0.849	0.978
IWM	0.733	0.240	0.879
TLT	0.213	0.265	-0.044
HYG	0.636	0.515	0.773
BTC-USD	0.207	0.329	0.631
JPM	0.435	0.106	0.680
NVDA	0.575	0.548	0.769

טבלה 3: קורלציה עם SPY כתלות ב-State Hidden של SPY בתקופת ה-Test.

התוצאה תומכת בפרשנות של ה-HMM כ-estimator: market-state latent ה-state אינו רק תיאור של תנודתיות, SPY אלא מתקשר גם לשינוי במבנה התלות בין asset classes. עם זאת, מדובר בניחות תיאורי על מדגם Test מוגבל: בתקופת החפיפה היו 325 ימים ב-State 0, אך רק 41 ימים ב-State 1 ו-46 ב-State 3, בעוד State 2 לא הופיע. לכן לא מוצגת כאן טענת מובהקות או סיבתיות לגבי שינויי הקורלציה.


6 תוצאות: חיזוי יום-קדימה

6.1 תמונה כללית

טבלה 4 מציגה את ממוצע ה-DPA הבלתי-משוקלל בין תשעת הנכסים. בניגוד לגרסה מוקדמת של הסיכום, כאן מוצגים גם שלושת ה-Baselines הפשוטים שהוגדרו מראש — Moving persistence, Chain Markov Discrete ו-Average — לצד מודלי ה-ML Supervised וה-HMM. התוצאה החשובה ביותר היא שאין מודל אחד שמציג יתרון חזויי עקבי.

Model	Mean DPA (%)
Naive - train mean	54.54
Logistic Regression	54.14
Discrete Markov Chain	53.90
Random Forest Classifier	53.27
Gaussian HMM - soft posterior	53.06
HistGradientBoostingClassifier	52.49
Gaussian HMM - hard state	52.06
Naive - persistence	50.45
Moving Average 5	50.27

טבלה 4: ממוצע DPA בין תשעת הנכסים לכל המודלים שנבדקו. הממוצע אינו שקול למבחן מובהקות ואינו מוכיח עליונות כללית של אף מודל.



איור 5: השוואת DPA לפי נכס עבור Naive, train-mean, שלושת מודלי ה-ML Supervised וה-HMM hard/soft. שלושת ה-Baselines הפשוטים הנוספים מוצגים בטבלה 4 אך אינם נכללים באיור כדי לשמור עליו קריא.

6.2 תוצאות לפי נכס

יש כמה מקרים מקומיים מעניינים. ב-QQQ, Forest Random השיג 59.22%, HMM soft השיג 58.98%, וה-Naive train-mean השיג 58.74%. ב-BTC-USD, Forest Random השיג 52.94% וה-soft HMM השיג 52.05%, לעומת 51.34% ל-Naive. ב-JPM, ה-Naive הגיע ל-57.52% בעוד HMM הגיע ל-51.70%. ב-TLT, HistGradientBoosting היה הטוב ביותר מבין המודלים שנבדקו עם 53.40%, בעוד HMM soft הגיע ל-47.09%; ה-Chain Markov Discrete הגיע שם ל-51.94%.

הפיזור הזה חשוב יותר מהדירוג הממוצע: HMM אינו נכשל בכל נכס, אך גם אינו מנצח בצורה יציבה. אותו דבר נכון למודלי ה-ML Supervised ול-Baselines הקלאסיים. לכן אין evidence לכך שה-Vector Feature הנוכחי מכיל signal חזק ועקבי לחיזוי next-day direction.

6.3 שגיאת magnitude: דוגמת SPY

DPA בודק רק את סימן התחזית, ולכן עבור המודלים שמחזירים תחזית מספרית לתשואה נבדקו גם MAE ו-RMSE על log next-day return ו-MAPE על מחיר הסגירה המשתמע. הטבלה הבאה מציגה את SPY, מקרה הייחוס המרכזי:

MAPE price (%)	RMSE return	MAE return	DPA (%)	Model
0.577	0.00766	0.00577	58.50	Naive - train mean
0.816	0.01043	0.00816	53.16	Naive - persistence
0.651	0.00846	0.00651	53.16	Moving Average 5
0.579	0.00769	0.00579	58.50	Discrete Markov Chain
0.577	0.00767	0.00577	58.50	Gaussian HMM - hard state
0.577	0.00767	0.00577	58.50	Gaussian HMM - soft posterior

טבלה 5: מדדי חיזוי מספריים על SPY. ההבדלים בין train-mean Naive ל-HMM קטנים מאוד; MAPE על מחיר מוצג כמדד משלים בלבד.

גם במדדי magnitude אין כאן יתרון מעשי גדול: HMM hard/soft כמעט זהים ל-Naive train-mean על SPY. הדבר מחזק את המסקנה שהערך המרכזי של ה-HMM בניסוי הנוכחי אינו תחזית נקודתית מדויקת יותר.

6.4 למה DPA לבדו עלול להטעות

ב-SPY, למשל, train-mean Naive ו-HMM מגיעים ל-DPA של כ-58.50%. עם זאת, Logistic Regression מגיע ל-DPA של 58.01% אך Accuracy Balanced של כ-49.6% ו-ROC-AUC של כ-47.3%. Forest Random משיג ROC-AUC של כ-50.4%. כלומר חלק ניכר מה-Accuracy נובע מחוסר איזון בין ימי Up ו-Down, ולא מיכולת חזקה לדרג ימים לפי הסתברות לעלייה.

זו הסיבה שבדוח לא מתייחסים ל-DPA מעל 50% כהוכחה אוטומטית ל-edge. predictive. מודל שמנבא את המחלקה הנפוצה יכול לקבל Accuracy סביר גם בלי להבין את דינמיקת היום הבא.


6.5 Hard state לעומת Soft posterior

בממוצע, HMM soft משיג 53.06% לעומת 52.06% ל-hard-state. הפער קטן, אך הוא עקבי עם האינטואיציה שלפיה שימוש בכל וקטור ה-posterior שומר מידע שנוזק ב- $\arg\max$. לדוגמה, ב-HMM hard QQQ הגיע ל-56.31% בעוד HMM soft הגיע ל-58.98%; ב-BTC-USD הפער גדול יותר, 48.13% לעומת 52.05%. מנגד קיימים גם נכסים שבהם soft אינו משפר.

לכן המסקנה אינה ש-soft posterior "פותר" את forecasting, אלא שהוא דרך הגיונית יותר לנצל uncertainty posterior מאשר hard assignment כאשר משתמשים ב-HMM לתחזית.

6.6 Walk-forward robustness על SPY

שלושת ה-folds walk-forward מציגים תמונה מעורבת. HMM soft השיג בהתאמה 50.36%, 51.82% ו-60.22%; train-mean Naive השיג 48.54%, 52.92% ו-59.85%. הממוצע הוא 54.14% ל-HMM soft לעומת 53.77% ל-Naive, אך HMM אינו מנצח בכל fold והפער הכולל קטן.



איור 6: DPA בשלושה folds walk-forward expanding על SPY ה-HMM אינו מפגין יתרון עקבי בין התקופות.

בדיקת ה-walk-forward מחזקת את הצורך בניסוח זהיר: ייתכן שמידע על regime מסייע בתקופות מסוימות, אך לא נמצא advantage predictive יציב שניתן להכליל לכל תקופה.

7 דיון

הממצא המרכזי של העבודה אינו HMM "מנבא את השוק", אלא כמעט ההפך: גם HMM, גם classifiers פשוטים וגם Baselines מתקשים להפיק signal עקבי לחיזוי היום הבא מתוך ארבעת ה-Features שנבדקו. התוצאה השלילית הזו אינה כישלון של הניסוי; היא מאפשרת להפריד בין שתי יכולות שונות של מודל — forecasting ו-representation.

7.1 למה חיזוי יום-קדימה נשאר קשה?

חיזוי סימן התשואה ליום הבא הוא בעיה בעלת יחס signal-to-noise נמוך. Features כמו rolling volatility ו-daily range מתארים היטב את סביבת הסיכון, אך אינם בהכרח מנבאים את סימן התשואה של יום בודד. העובדה שגם Logistic Regression, Forest Random Regression ו-HistGradientBoosting אינם מייצרים יתרון עקבי תומכת בפרשנות שהקושי אינו ייחודי ל-HMM.

בנוסף, DPA רגיש ל-class balance. בתקופות שבהן שיעור ימי העלייה גבוה, baseline פשוט שמנבא את הכיוון הדומיננטי יכול להשיג DPA מעל 50%. לכן Accuracy Balanced ו-ROC-AUC חשובים לבדיקת signal חיזוי אמיתי. ברוב הנכסים מדדים אלה נשארו קרובים ל-50%, ולכן לא נכון להסיק מה-DPA בלבד שיש יכולת forecasting חזקה.

7.2 מה ה-HMM כן מוסיף?

בניגוד ל-classifier, HMM בונה ייצוג מפורש של מצב לטנטי ושל דינמיקת המעבר בין states ב-SPY. ההפרדה בין states ניכרת במספר ממדים בוזמנית: return, volatility, range, drawdown. ה-time dwell posterior גבוה ברוב הימים, והאנטרופיה עולה כאשר המודל נמצא באזור ambiguity בין states. חשוב לא להפריז בפרשנות של הקשר הזה: מאחר ש-hard switch נגרז מאותו entropy posterior גבוהה סביב switch היא בחלקה תוצאה צפויה של הגדרת הגבול. לכן זהו diagnostic פנימי של confidence, לא validation עצמאי.

הראיות החיצוניות יותר מגיעות ממקומות אחרים: VIX שלא שימש באימון מפריד בין חלק מה-states, והקורלציה של SPY עם נכסים אחרים משתנה לפי state. גם כאן מדובר ב-descriptive post-hoc.

evidence ולא בהוכחה סיבתית, אך הוא מראה שה-state קשור למאפייני שוק שאינם חלק ישיר מה-Vector Feature של SPY.

לכן ה-HMM מספק **conditional market context**. במקום לשאול רק "האם מחר יהיה Up?", ניתן לשאול "באיזה סוג סביבה סטטיסטית אנחנו נמצאים, כמה המודל בטוח בכך, וכיצד נכסים אחרים נוטים להתנהג בסביבה זו?". זו יכולת שאינה נמדדת ישירות ב-DPA.

7.3 Expressiveness מול robustness

העבודה מראה גם trade-off בין מספר states לבין יציבות. $K = 2$ נוטה להיות יציב מאוד בין seeds אך גם יחסית. $K = 4$ מאפשר להפריד states עשירים יותר, וב-SPY, QQQ ו-NVDA הוא גם יציב מאוד. לעומת זאת ב-BTC-USD וב-GLD הוא רגיש יותר לאתחול. מכאן שאין הצדקה לקבוע מספר states אוניברסלי לכל class. asset.

7.4 האם ניתן לקרוא ל-"Bull", "Bear" ו-"Crash"?

לא באופן אוטומטי. מספר state הוא label שרירותי, והמודל אינו לומד מושגים כלכליים בשפה אנושית. לכן בדוח נעשה שימוש בשמות תיאוריים רק כאשר הנתונים תומכים בהם. למשל 2 State של SPY מכונה crisis-like משום שהוא נדיר, בעל return שלילי, volatility גבוהה ו-drawdown עמוק. גם שם זה הוא פרשנות ולא ground truth.

7.5 משך המשטר והנחת Markov

ההשוואה בין $1/(1 - a_{ii})$ לבין time dwell אמפירי לא חשפה פער גדול בממוצע עבור SPY. לכן אין בסיס לטעון שהנחת duration הגאומטרית נכשלת בניסוי זה. עם זאת, בדיקת ממוצעים אינה בוחנת tails או multimodality של Model Semi-Markov Hidden durations; יכול להיות הרחבה טובה אם רוצים למדל משך משטר במפורש [4].

בסיכום, התמונה העקבית ביותר היא שה-Gaussian HMM מתאים בפרויקט זה יותר ל-latent state estimation מאשר ל-point forecasting. זו אינה נסיגה מהמטרה המקורית אלא ממצא אמפירי שמגדיר בצורה מדויקת יותר היכן המודל מספק ערך.

8 הרחבה עתידית: Regime-aware Reinforcement Learning

הרחבה טבעית של הפרויקט היא מעבר מבעיה של חיזוי לבעיה של קבלת החלטות סדרתית. ב-Learning Supervised אנו מנסים ללמוד פונקציה מה-Features אל יעד ידוע מראש, למשל $P(y_{t+1} = 1 | x_t)$. ב-Learning Reinforcement הסוכן אינו נדרש רק לומר מה צפוי לקרות; הוא בוחר פעולה המשפיעה על הרווח המצטבר לאורך זמן.

8.1 ניסוח כ-Markov Decision Process

ניתן להגדיר את בעיית המסחר כ-MDP שבו בכל יום קיימים action observation, ו-reward. לדוגמה:

• **Observation:** ארבעת ה-Features הנוכחיים, probabilities posterior של ה-HMM, entropy, והפוזיציה הנוכחית בתיק.

• **Action:** בגרסה פשוטה buy / hold / sell; בגרסה רציפה יותר — משקל $w_t \in [0, 1]$ בנכס.

• **Reward:** תשואת התיק נטו לאחר costs, transaction penalty עם turnover או לסיכון.

ניסוח אפשרי של reward הוא:

$$R_{t+1} = w_t r_{t+1} - c|w_t - w_{t-1}| - \lambda \text{RiskPenalty}_{t+1}, \quad (11)$$

כאשר c מייצג עלות עסקה ו- λ את משקל רתיעת הסיכון. בניגוד לניסוי החיזוי הנוכחי, כאן transaction costs אינם פרט שולי: policy שמחליפה פוזיציה לעיתים קרובות יכולה להיראות מוצלחת לפני עלויות ולהיכשל לאחריהן.

8.2 למה לשלב HMM בתוך RL?

הרעיון המעניין ביותר אינו להחליף את ה-HMM ב-RL, אלא להשתמש ב-HMM כשכבת state estimation. במקום לתת לסוכן label hard כמו State "3", ניתן להזין את כל הווקטור

$$[\gamma_t(1), \dots, \gamma_t(K), H_t], \quad (12)$$

כך שהסוכן יודע גם מהו regime הסביר וגם כמה ה-HMM בטוח בו. לדוגמה, policy יכולה ללמוד באופן עצמאי שתקופה בעלת posterior חד דורשת פעולה שונה מתקופה שבה שני states מתחרים ביניהם. אין צורך לקודד מראש כלל כמו ב-state crisis מוכרים; ה-RL בודק אם מידע זה אכן מועיל ל-reward.

הניסוי הנקי ביותר יהיה ablation בשלוש רמות:

1. **RL-Features:** הסוכן רואה רק את ארבעת ה-Features המקוריים.
2. **RL-Regime:** אותם Features בתוספת HMM posterior probabilities.
3. **RL-Regime-Uncertainty:** תוספת entropy posterior ומידע על הפוזיציה הנוכחית.

השוואה כזו הייתה עונה על שאלה ממוקדת: האם מידע לטנטי על regime מוסיף ערך אינקרמנטלי למדיניות מעבר למידע הגולמי שכבר קיים ב-Features? זהו המשך ישיר יותר של העבודה מאשר להריץ אלגוריתם RL שאינו משתמש בתוצאות ה-HMM.

8.3 אלגוריתמים אפשריים

לפעולות דיסקרטיות ניתן להתחיל במודל actor-critic פשוט. לפעולות allocation רציפה, שתי אפשרויות טבעיות הן PPO [15] ו-SAC Soft Actor-Critic [6]. PPO נפוץ בגלל עדכונים יציבים יחסית באמצעות SAC objective; clipped entropy; exploration באמצעות entropy.

קיימות מסגרות ייעודיות כמו FinRL, שנבנו כדי לפשט את הגדרת סביבת המסחר, pipeline data ו-frictions market [11]. עם זאת, שימוש בספרייה אינו פותר את שאלות המתודולוגיה: עדיין צריך להגדיר, seeds multiple train/validation/test, costs, transaction actions, reward, evaluation. forward

8.4 מה מראה הספרות?

התמונה בספרות אינה חד-משמעית. al. et Yang אימנו ensemble של A2C PPO ו-DDPG על 30 מניות Jones Dow ודיווחו על ratio Sharpe גבוה יותר מהמדד ומתיק minimum-variance בניסוי שלהם [17]. Roberts and Zohren Zhang בחנו Deep RL על 50 חוזים עתידיים ממספר asset classes ודיווחו על ביצועים חיוביים גם בנוכחות transaction costs משמעותיים [18].

מצד שני, תוצאות חיוביות אינן מובטחות כאשר מרחיבים את הבדיקה. Müller and Kruthof בחנו SAC על שבעה datasets של מניות עם יותר מ-300 שנות out-of-sample מצטברות. הם מצאו שהמודל לא ניצח באופן שיטתי baseline של $1/N$ גם ללא frictions, וש- turnover גבוה גרם לביצועים נטו שליליים כבר תחת עלויות עסקה מתונות של 0.1% [10]. המסקנה מכאן אינה ש-RL "לא עובד", אלא שהערכתו רגישה מאוד לפרוטוקול, לעלויות ולבחירת benchmark.

8.5 כיצד היינו מבצעים את הניסוי בצורה הוגנת?

כדי שהרחבה כזו תהיה משכנעת, היינו שומרים על אותם עקרונות שהנחנו את הפרויקט הנוכחי:

- חלוקה כרונולוגית ו-walk-forward, ללא shuffle.
- התאמת HMM ו-scaler על המידע הזמין באותו fold בלבד.
- seeds multiple לכל policy, משום ש-RL Deep רגיש לאתחול.
- costs transaction ו-turnover מפורשים ב-reward ובהערכה.
- Baselines כגון policy Average, Moving Buy-and-Hold, ללא HMM, ו-policy עם HMM.
- מדדים כגון Sharpe, return, cumulative drawdown maximum ו-turnover, לצד בדיקה אם התוצאות שורדות עלויות עסקה.

לא בוצע ניסוי RL בדוח הנוכחי, ולכן אין כאן טענה שהרחבת RL Regime-aware תשפר ביצועים. היא מוצגת ככיוון מחקר שמנצל באופן ישיר את הממצא המרכזי של העבודה: ה-HMM נראה שימושי יותר כ-estimator state מאשר כ-one-step predictor. RL הוא מסגרת טבעית לבדוק האם state estimate כזה מועיל כאשר הבעיה מוגדרת כקבלת החלטות לאורך זמן ולא כחיזוי סימן של יום בודד.

9 מגבלות

למרות ההרחבות שבוצעו, קיימות מספר מגבלות שחשוב להציג במפורש.

- **Features מוגבלים:** ארבעת ה-Features פשוטים ומכוונים למצב השוק, אך ייתכן שהם אינם מכילים signal מספיק לחיזוי next-day direction. הוספת macro options-implied data, variables או order-flow יכולה לשנות את התמונה, אך גם להגדיל סיכון ל-overfitting ול-snooping.

- **תקופת Test אחת לכל נכס:** נוסף walk-forward על SPY בלבד. לכן robustness בזמן בבדיקה לעומק עבור נכס הייחוס, אך לא עבור כל תשעת הנכסים.

- **בחירת K:** selection model לפי likelihood Validation העדיף ברוב הנכסים $K = 4$. למרות בדיקת stability, seed עדיין ייתכן שמספר states מתאים משתנה בין תקופות או assets.

- **labels: Semantic** שמות כמו calm או crisis-like הם פרשנות post-hoc ולא ground truth. ה-HMM אינו "יודע" מהו משבר כלכלי.

- **VIX validation חלקי:** 2 State הנדיר של SPY לא הופיע בחפיפה עם תקופת ה-Test ולכן לא קיבל validation external מול VIX באותו חלון.

- **Supervised baselines אינם tuning תחרותי:** Logistic Regression, Random Forest ו-HistGradientBoosting נבחרו כ-Baselines שקופים עם hyperparameters קבועים. המטרה לא הייתה להוכיח מהו classifier הטוב ביותר האפשרי.

- **היקף אימון לא זהה בכל ההשוואות:** לאחר בחירת K ו-seed, ה-HMM הסופי וה-Baselines הפשוטים משתמשים בכל היסטוריית Train+Validation הזמינה לפני Test. מודלי ה-Supervised הקבועים אומנו על Train בלבד ו-Validation נשאר ללא שימוש. לכן השוואת ה-DPA ביניהם היא אינדיקציה משלימה ולא ניסוי שבו לכל המודלים הוקצתה בדיוק אותה כמות נתוני אימון.

- **אין backtest למסחר:** DPA אינו שקול לרווחיות. לא נכללו עמלות, taxes slippage או sizing position ולכן אין להסיק מהתוצאות המלצה למסחר.

10 מסקנות

העבודה התחילה משאלה חילונית: האם Gaussian HMM יכול לזהות States Hidden ולנצל אותם כדי לשפר forecasting. direction next-day. לאחר סדרת ניסויים רחבה יותר התקבלה תשובה מפוצלת.

מבחינת forecasting, אין יתרון עקבי. ממוצע ה-DPA בין תשעת הנכסים היה 54.54% ל-Naive, 53.27% Chain, Markov Discrete ל-53.90% Regression, Logistic ל-54.14% train-mean, 52.06% HistGradientBoosting ל-52.49% HMM, soft ל-53.06% Forest, Random ל-50.45% HMM, hard ל-50.27% persistence Naive ל-50.27% Average Moving ל-5. גם forward SPY על מציג פערים קטנים ולא עקביים, ובמדדי MAE/RMSE על SPY ה-HMM כמעט זהה ל-Naive. train-mean. Naive לאור מגבלת היקף האימון הלא-זהה בין HMM ל-Supervised baselines, אין לפרש את הדירוג הממוצע כתחרות מובהקת ביניהם. בכל מקרה, התוצאות אינן מספקות בסיס לטעון שה-HMM "מנבא את השוק" או מציג יתרון יציב על Baselines פשוטים.

מבחינת structure, latent התוצאה חזקה יותר. ב-SPY מתקבלים ארבעה states בעלי מאפייני drawdown range, volatility, return, ומשך שונים. State נדיר אחד מציג מאפייני stress ברורים. חלוקת $K = 4$ יציבה מאוד בין entropy posterior seeds; עולה סביב switches state אך מפורש כ-diagnostic פנימי של VIX ambiguity; חיצוני מפריד בין חלק מה-states; והקורלציה של SPY עם risk אחרים משתנה כתלות במשטר.

לכן המסקנה הסופית היא שה-Gaussian HMM בפרויקט זה מתאים יותר ל-modeling **conditional market structure** מאשר ל-point forecasting. הערך שלו אינו בכך שהוא יודע בוודאות מה יקרה מחר, אלא בכך שהוא נותן הקשר הסתברותי: באיזה סוג regime השוק נמצא, כמה זה מתמשך, כמה המודל בטוח בזיהוי, וכיצד מבנה הסיכון והקשרים בין נכסים משתנים יחד איתו.

הרחבה טבעית היא להשתמש ב-posterior של ה-HMM כ-representation state בתוך Regime-aware Reinforcement Learning, ולבדוק האם מידע זה משפר policy לאורך זמן תחת transaction costs ו-walk-forward evaluation. זוהי שאלה מחקרית שונה מהחילוי שנבדק כאן, והיא דורשת ניסוי נפרד ולא inference מתוך התוצאות הנוכחיות.

א' שחזור והרצה

הדוח והמחברת קוראים תוצאות machine-readable מה-artifacts המאומתים, ולכן ניתן לעיין בהם בלי לאמן מחדש את כל המודלים. הריצות המרכזיות הן:

• [experiments_extended/extended_20260811_121957/](#)

• [experiments_supervised/supervised_20260811_133344/](#)

סביבת הריצה המאומתת הייתה Python 3.11.15. בריצת ה-HMM נעשה שימוש ב-hmmlearn, 0.3.3 NumPy, 2.4.6 pandas, ו-1.9.0 scikit-learn.

להרצה מחדש:

```
python -m pip install -r requirements.txt
python run_extended_analysis.py
python analyze_extended_context.py \
  --run-dir experiments_extended/<run_id>
python run_supervised_baselines.py
jupyter nbconvert --to notebook --execute \
  HMM_Market_Regimes_Project.ipynb \
  --output /tmp/HMM_verified.ipynb \
```

--ExecutePreprocessor.timeout=600

כל ריצה חדשה נכתבת לתיקייה timestamped חדשה ואינה אמורה לדרוס את התוצרים שעליהם מבוסס הדוח. הדבר חשוב במיוחד משום שמקור הנתונים חיצוני ונתוני Finance Yahoo יכולים להתעדכן לאורך זמן.

מקורות

- [1] Hirotugu Akaike. A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6):716–723, 1974.
- [2] Ran Aroussi. yfinance: Download market data from yahoo! finance's api. Python software and documentation, 2024.
- [3] Leonard E. Baum, Ted Petrie, George Soules, and Norman Weiss. A maximization technique occurring in the statistical analysis of probabilistic functions of markov chains. *The Annals of Mathematical Statistics*, 41(1):164–171, 1970.
- [4] Jan Bulla and Ingo Bulla. Stylized facts of financial time series and hidden semi-markov models. *Computational Statistics & Data Analysis*, 51(4):2192–2209, 2006.
- [5] Luigi Catello, Ludovica Ruggiero, Lucia Schiavone, and Mario Valentino. Hidden markov models for stock market prediction. *arXiv preprint arXiv:2310.03775*, 2023.
- [6] Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *Proceedings of the 35th International Conference on Machine Learning*, pages 1861–1870, 2018.
- [7] James D. Hamilton. A new approach to the economic analysis of nonstationary time series and the business cycle. *Econometrica*, 57(2):357–384, 1989.
- [8] hmmlearn developers. hmmlearn: Hidden markov models in python. Software documentation, 2024.
- [9] Rob J. Hyndman and Anne B. Koehler. Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4):679–688, 2006.
- [10] Garvin Kruthof and Sebastian Müller. Can deep reinforcement learning beat 1/n? *Finance Research Letters*, 75:106866, 2025.
- [11] Xiao-Yang Liu, Hongyang Yang, Jiechao Gao, and Christina Dan Wang. Finrl: Deep reinforcement learning framework to automate trading in quantitative finance. *arXiv preprint arXiv:2111.09395*, 2021.
- [12] Kevin P. Murphy. *Machine Learning: A Probabilistic Perspective*. MIT Press, Cambridge, MA, 2012.
- [13] Jennifer Pohle, Roland Langrock, Floris M. van Beest, and Niels M. Schmidt. Selecting the number of states in hidden markov models: Pragmatic solutions illustrated using animal movement. *Journal of Agricultural, Biological and Environmental Statistics*, 22:270–293, 2017.
- [14] Lawrence R. Rabiner. A tutorial on hidden markov models and selected applications in speech recognition. *Proceedings of the IEEE*, 77(2):257–286, 1989.
- [15] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- [16] Gideon Schwarz. Estimating the dimension of a model. *The Annals of Statistics*, 6(2):461–464, 1978.
- [17] Hongyang Yang, Xiao-Yang Liu, Shan Zhong, and Anwar Walid. Deep reinforcement learning for automated stock trading: An ensemble strategy. In *Proceedings of the First ACM International Conference on AI in Finance (ICAIF '20)*, pages 1–8, 2020.
- [18] Zihao Zhang, Stefan Zohren, and Stephen Roberts. Deep reinforcement learning for trading. *arXiv preprint arXiv:1911.10107*, 2019.